



INSI UNIVERSITY

INSTITUT NATIONAL SUPERIEUR D'INFORMATIQUE

MEMOIRE DE STAGE EN VUE DE LA VALIDATION DU MASTER 1

Domaine : Sciences et Technologies

Mention : Informatique

Parcours : Management des Systèmes d'Information

Par : Madame CHRYSTOSTOME Priscillia

**CONCEPTION ET RÉALISATION D'UNE PLATEFORME D'AGENTS
D'INTELLIGENCE ARTIFICIELLE SÉCURISÉS POUR L'OPTIMISATION DES
PROCESSUS MÉTIERS ET LE RENFORCEMENT DE LA CYBERSÉCURITÉ**

Soutenu le 29 Mai 2026 à 13h00, devant la Commission d'Examen composée de :

Président de Jury : Docteur RAPATSALAHY Miary Andrianjaka

Examineurs : Docteur SONIARIMAMY Nantenaina Serge Rochel
Docteur RAKOTONIRINA Alain Barnabé

Directrice de mémoire : Docteur FANOMEZANA Mihajaso Léa

Encadreur professionnel : Monsieur BIDEAU Jean-Pierre

Année Universitaire : 2025 – 2026

REMERCIEMENTS

Avant tout, nous rendons grâce à Dieu Tout-Puissant pour la force, la santé et la persévérance qu’Il nous a accordées tout au long de ce travail.

Nous adressons nos sincères remerciements à Monsieur RAMASONDRANO Andriamanjaka, Docteur Ingénieur en Intelligence Artificielle, Data Science et Cybersécurité et Fondateur de Institut National Supérieur d’Informatique (INSI) ainsi qu’à Monsieur ANDRIAMIADANA Tantely Antoine, Enseignant à l’INSI et Chef du Parcours Master en Système d’Information, pour la qualité de l’encadrement institutionnel et les conditions d’études qu’ils ont su mettre en place au sein de notre établissement.

Nous exprimons notre profonde gratitude à Madame FANOMEZANA Mihajaso Léa, Docteur en Informatique et Directrice de ce mémoire, pour sa disponibilité constante, ses conseils avisés et la rigueur scientifique avec laquelle elle a guidé nos travaux. Ses orientations méthodologiques ont été déterminantes dans l’aboutissement de cette recherche.

Nos remerciements vont également à l’ensemble des enseignants du département Informatique de l’INSI, dont l’engagement pédagogique et les enseignements dispensés au cours de notre formation ont constitué un socle indispensable à la réalisation de ce travail. Nous remercions par la même occasion les membres du jury qui ont bien voulu consacrer leur temps et leur expertise à l’évaluation de ce mémoire.

Nous témoignons notre reconnaissance au personnel administratif et technique de l’INSI pour leur assistance efficace dans les démarches administratives liées à la préparation et au dépôt de ce mémoire.

Nous tenons à remercier chaleureusement Monsieur Jean-Pierre BIDEAU, CEO et Encadreur professionnel, pour la confiance qu’il nous a témoignée et pour le temps qu’il a consacré à la supervision de nos travaux de recherche et de programmation ainsi que l’ensemble de l’équipe de CyberInTrust en France, pour leur accueil, leur collaboration et les ressources qu’ils ont mises à notre disposition durant la réalisation de ce projet.

Enfin, nous dédions ce travail à notre famille, en particulier à nos parents, dont le soutien indéfectible, les sacrifices consentis et les encouragements répétés ont été notre source de motivation la plus profonde. Nos remerciements s’adressent aussi à nos amis et camarades de promotion pour leur solidarité, leur bonne humeur et les moments de travail partagés qui ont rendu ce parcours plus enrichissant.

Priscillia CHRYSOSTOME

RESUME

Les grands modèles d'intelligence artificielle généraliste peinent à répondre aux exigences des entreprises en termes de fiabilité, de coût et de retour sur investissement. Face à ces limites, l'IA Agentique s'impose comme une approche plus pragmatique, ancrée dans les piliers existants du système d'information tels que les données internes, référentiel documentaire, processus métiers et expertises des collaborateurs. Par conséquent, ce mémoire s'inscrit dans cette perspective et répond à la problématique : comment une entreprise peut-elle intégrer des agents d'intelligence artificielle spécialisés au sein de son système d'information afin d'améliorer la performance des processus métiers et la gestion des incidents de cybersécurité, tout en garantissant la gouvernance des données, la sécurité du SI et le contrôle humain ? Pour répondre à cette question, nous avons adopté une démarche en trois phases. La première est l'analyse théorique des concepts fondamentaux : IA agentique, système d'information et cybersécurité. La deuxième phase porte sur la conception d'un framework d'intégration d'agents IA, conforme aux recommandations de l'OWASP et aux principes de l'IA Act Européen qui est articulé autour d'un cas d'usage de gestion d'incidents. Enfin, la troisième phase est consacrée à la réalisation, aux tests et à l'évaluation du prototype dans sa version 0.1. Les résultats montrent la faisabilité de concevoir un agent IA spécialisé, capable de s'insérer dans un processus métier hybride pour le diagnostic d'incidents et leur qualification en incidents de cybersécurité potentiels, tout en respectant les exigences de la gouvernance et de contrôle humain. Le framework proposé constitue une base opérationnelle pour le déploiement d'agents IA au sein des systèmes d'information d'entreprise.

Mots-clés : intelligence artificielle agentique, système d'information, cybersécurité, processus métier, gouvernance des données, OWASP, IA Act.

ABSTRACT

General purpose large AI models struggle to meet companies requirements regarding reliability, cost and return in investment. In response to these limitations, agentic AI emerges as a more pragmatic approach, grounded in the existing pillars of the information system : internal data, document repositories, business processes, and employee expertise. In consequence, this thesis addresses the following research question : how can a company integrate specialized artificial intelligence agents within its information system to improve business process performance and cybersecurity incident management, while ensuring data governance, IS security, and human oversight ? To answer this question, we followed the feasibility of designing a specialized AI agent which is capable of integrating into a hybrid business process for incident diagnosis and potential reclassification as cybersecurity incidents, while complying with governance and human control requirements. The proposed framework provides an operational foundation for deploying AI agents within enterprise information systems.

Key words : agentic artificial intelligence, information system, cybersecurity, business process, data governance, OWASP, AI Act

SOMMAIRE

REMERCIEMENTS	i
RESUME	ii
ABSTRACT	ii
LISTE DES ABREVIATIONS	iv
GLOSSAIRE	vi
LISTE DES TABLEAUX	xiii
LISTE DES FIGURES	xiv
INTRODUCTION	1
I	2
CONTEXTE GENERAL DU PROJET	2
I.1 Présentation de l'entreprise	2
I.2 Présentation de l'INSI	4
I.3 Identification du projet	10
I.4 Méthodologie	13
II	18
ANALYSE ET CONCEPTION	18
II.1 Analyse du système actuel	18
II.2 Expression des besoins	21
II.3 Conception du système futur	23
III	32
REALISATION	32
III.1 Choix et présentation des outils	32
III.2 Structure générale de l'application	34
III.3 Description technique du logiciel	46
IV	52
EVALUATION DU PROJET ET PERSPECTIVES	52
IV.1 Etude des risques	52
IV.2 Coût de mise en oeuvre	58
IV.3 Perspectives	58
CONSLUSION	60
BIBLIOGRAPHIE	XVI
WEBOGRAPHIE	XVII
ANNEXE	XVIII
5em 6.5em	
Annexe 1 –Couche réseau Nginx de l'architecture Zero Trust	XVIII
Annexe 2 –Couche authentification Keycloak + JWT	XVIII

Annexe 3	P rotection contre les injections de prompts	XIX
Annexe 4	E tape 1 : Chargement des documents dans la phase d'ingestion	XIX
Annexe 5	E tape 2 : Découpage en fragments ou Chunking dans la phase d'ingestion	XX
Annexe 6	E tape 3 : Vectorisation ou Embedding dans la phase d'ingestion	XX
Annexe 7	E tape 4 : Indexation dans ChromaDB durant la phase d'ingestion	XX
Annexe 8	R echerche par similarité	XXI
Annexe 9	C onstruction du prompt et génération	XXII
Annexe 10	C onstruction des features	XXIII
Annexe 11	E ntraînement du modèle de classification	XXIII
Annexe 12	S tructure du projet Flutter	XXIV
Annexe 13	S tockage sécurisé du JWT (Flutter)	XXV
Annexe 14	C lient HTTP et gestion des requêtes	XXV
Annexe 15	A analyse de la conformité d'un traitement	XXVI
Annexe 16	R éponse contextualisée générée par le chatbot	XXVI
Annexe 17	C réation du client Dio avec injection automatique du JWT et gestion d'erreur 40	XXVII
Annexe 18	C onfiguration de l'URL de base de l'API	XXVII
Annexe 19	O WASP Top 10 - Risques principaux	XXVIII

LISTE DES ABREVIATIONS

Abréviation	Signification
ACID	Atomicité, Cohérence, Isolation, Durabilité
ANSSI	Agence Nationale de la Sécurité des Systèmes d'Information
API	Application Programming Interface
AUC-ROC	Area Under the Curve – Receiver Operating Characteristic
BERT	Bidirectional Encoder Representations from Transformers
BGL	Blue Gene/L
CEF	Common Event Format
CNIL	Commission Nationale de l'Informatique et des Libertés
CSV	Comma-Separated Values
DPIA/AIPD	Data Protection Impact Assessment / Analyse d'Impact relative à la Protection des Données
DDoS	Distributed Denial of Service
DoS	Denial of Service
DPO	Data Protection Officer
ERP	Enterprise Resource Planning
FCM	Firebase Cloud Messaging
F1	F1-Score (métrique d'évaluation)
GPU	Graphics Processing Unit
HDFS	Hadoop Distributed File System
HTTP	HyperText Transfer Protocol
HTTPS	HyperText Transfer Protocol Secure
IA	Intelligence Artificielle
IAM	Identity and Access Management
INSI	Institut National Supérieur d'Informatique
IoT	Internet of Things
ISO	International Organization for Standardization
JIT	Just In Time
JSON	JavaScript Object Notation
JWT	JSON Web Token
LLM	Large Language Model
LSTM	Long Short-term Memory
NIST	National Institute of Standards and Technology
OWASP	Open Web Application Security Project
PDF	Portable Document Format
PIA	Privacy Impact Assessment
PME	Petites et Moyennes Entreprises
RAG	Retrieval-Augmented Generation
RBAC	Role Based Access Control
REST	Representational State Transfer
ROI	Return On Investment

SAML	Security Assertion Markup Language
SIEM	Security Information and Event Management
SMOTE	Synthetic Minority Over-sampling Technique
SOC	Security Operations Center
SQL	Structured Query Language
SSL	Security Sockets Layer
SVM	Support Vector Machine
TCP	Transmission Control Protocol
TLS	Transport Layer Security
SI	Système d'Information
TF-IDF	Term Frequency – Inverse Document Frequency
UML	Unified Modeling Language
URL	Uniform Resource Locator
OAuth2	Open Authorization 2.0
XSS	Cross-Site Scripting

GLOSSAIRE

Mot	Définition
Agent IA	C'est un système logiciel d'intelligence artificielle conçu pour percevoir son environnement, raisonner sur des informations et agir de façon autonome pour atteindre un objectif précis. Il peut enchaîner plusieurs étapes de raisonnement, consulter des bases de données, appeler des outils externes et produire des résultats structurés (Wooldridge & Jennings, 1995).
AI Act	C'est un règlement européen sur l'intelligence artificielle (Règlement UE 2024/1689), entré en vigueur en 2024 qui établit un cadre juridique contraignant pour les systèmes d'IA, avec une classification par niveau de risque (interdit, obligations strictes, transparence et libre). Les systèmes d'IA utilisés en cybersécurité et en conformité réglementaire relèvent généralement du risque élevé ou limité (Journal officiel de l'Union européenne, L 2024/1689, 13 Juin 2024).
AIPD	Il signifie Analyse d'Impact relative à la Protection des Données (ou DPI en français). C'est une étude obligatoire imposée par le RGPD pour les traitements susceptibles d'engendrer un risque élevé pour les droits et libertés des personnes concernées. Elle doit décrire le traitement, évaluer les risques et identifier les mesures pour y remédier (CNIL, 2018).
ANSSI	C'est l'Agence Nationale de la Sécurité des Systèmes d'Information. Il s'agit d'une autorité française en matière de cybersécurité au Secrétariat général de la défense et de la sécurité nationale (SGDSN). Elle publie des référentiels, des guides techniques et des recommandations à destination des organismes publiques et privés (http://anssi.gouv.fr).
API	Application Programming Interface (Interface de Programmation Applicative). Il s'agit d'un ensemble de règles et de spécifications qui permettent à deux logiciels de communiquer entre eux (Fielding & Reschke, 2014).
Architecture en couches	C'est un principe de conception logicielle qui organise un système en niveaux distincts tels que la présentation, l'applicatif, le métier et les données où Chaque couche n'interagisse qu'avec la couche adjacente (https://ladjicisse.com/docs/architecture/types/en-couches/).
Authentification	C'est un processus de vérification de l'identité de l'utilisateur ou d'un système (Rose et al.,2020)
Autorisation	C'est un processus qui détermine, après authentification, quelles ressources et fonctionnalités un utilisateur est autorisé à utiliser (https://www.exclusive-networks.com/ca-fr/ressources/base-de-connaissances/glossaire/autorisation).
Backend	C'est la partie d'une application qui s'exécute côté serveur, il est invisible pour l'utilisateur final. Elle gère la logique métier, les accès aux bases de données et les appels aux services externes (https://aws.amazon.com/fr/compare/the-difference-between-frontend-and-backend/).
Base de données relationnelle	C'est un système de stockage de données organisé sous forme de tables liées entre elles par des relations. Elle garantit l'intégrité des données via les contraintes ACID (Atomicité, Cohérence, Isolation et Durabilité), (Laudon & Laudon, 2020).

Base de données vectorielle	C'est une Base de données spécialisée dans le stockage et la recherche de vecteurs (embeddings). Elle permet des recherches de similarité sémantique qui sont fondamentales dans les pipelines RAG (Lewis et al., 2020) .
Base légale	Dans le contexte du RGPD, c'est le fondement juridique qui légitime un traitement de données personnelles (Journal Officiel de l'Union Européenne, 2016).
Chatbot	C'est un programme informatique qui simule une conversation avec un utilisateur humain via une interface textuelle. Contrairement à un agent IA, un chatbot classique se base sur des règles prédéfinies ou des réponses scriptées (https://aws.amazon.com/fr/what-is/chatbot/).
CrhomaDB	C'est une base de données vectorielle open source, légère et facile à déployer localement. Elle est utilisée dans notre projet pour indexer et rechercher les embeddings des documents de la base de connaissance RGPD par des recherches de similarité sémantique en quelques millisecondes (https://docs.trychroma.com/docs/overview/introduction).
Chunk	Il s'agit d'un fragment de texte issu du découpage d'un document lors de la phase d'ingestion du pipeline RAG. La taille des chunks (généralement entre 256 et 1024 tokens) et le chevauchement entre chunks (overlap) influencent directement la qualité des réponses de l'agent, (Lewis et al., 2020)).
Classification	C'est une tâche d'apprentissage automatique qui consiste à attribuer une catégorie (label) à une observation en entrée, (Breiman, 2001).
CNIL	C'est la Commission Nationale de l'Informatique et des Libertés. C'est l'autorité administrative indépendante française chargée de veiller au respect de la loi informatique et Libertés et du RGPD. Elle accompagne les organisations dans leur mise en conformité, instruit les plaintes et prononce des sanctions en cas de violation (Journal Officiel de l'Union Européenne, 2016).
Confidentialité	C'est une propriété de sécurité garantissant que des informations ne sont accessibles qu'aux personnes autorisées. Il s'agit de l'un des trois piliers de la sécurité de l'information avec l'intégrité et la disponibilité qui constitue la triade CIA (Rose et al., 2020).
Conformité	C'est l'état d'une organisation dont les pratiques, processus et systèmes respectent les exigences légales, réglementaires ou normatives applicables à son secteur (https://formation.lefebvre-dalloz.fr/dossier/conformite-en-entreprise).
Contexte documentaire	Dans le paradigme RAG, c'est un ensemble de fragments de documents sélectionnés par la recherche vectorielle et transmis au modèle de langage pour enrichir sa réponse. La qualité du contexte documentaire est le principal facteur déterminant la pertinence des réponses de l'agent (https://scienceetbiencommun.pressbooks.pub/projetthese/chapter/quelle-est-la-place-du-contexte-dans-une-recherche/).
Cybersécurité	Il s'agit d'un ensemble de pratiques, technologie et processus visant à protéger les systèmes informatiques, les réseaux et les données contre les attaques, les dommages et les accès non autorisés. Elle repose sur trois piliers à savoir la confidentialité, l'intégrité et la disponibilité (ENISA, 2020).
Chiffrement	C'est la transformation d'une information lisible en une forme inintelligible sans la clé appropriée. Elle garantit la confidentialité des données en transit (via SSL/TLS) et au repos (via le chiffrement des bases de données). Il est fondamental dans une architecture Zero Trust (https://aws.amazon.com/fr/what-is/data-encryption/).

Données personnelles	C'est toute information se rapportant à une personne physique identifiée ou identifiable qui inclut le nom, l'adresse, le numéro de téléphone, l'adresse e-mail, les données de santé, la localisation, les identifiants en ligne, etc. Le RGPD encadre strictement leur traitement (Journal Officiel de l'Union Européenne, 2016).
DPO	Il signifie Data Protection Officer (Délégué à la Protection de Données). Il s'agit d'une personne désignée au sein d'une organisation pour superviser la conformité RGPD, conseiller les équipes, constituer le registre de traitements et servir d'interlocuteur avec la CNIL. Sa désignation est obligatoire pour certaines catégories d'organisations.
DPIA	Il signifie Data Protection Impact Assessment (voir AIPD). C'est une analyse obligatoire pour les traitements à risque élevé. Elle comprend une description du traitement, une évaluation de la nécessité et de la proportionnalité, une évaluation des risques les personnes et les mesures envisagées (Article 37-39 du RGPD, 2016).
Embedding	Il s'agit d'une représentation vectorielle d'un texte, d'une image ou de tout autre donnée dans un espace mathématique de haute dimension. Deux textes sémantiquement proches auront des embeddings proches dans cet espace, ce qui permet des calculs de similarité (Lewis et al., 2020).
Endpoint	C'est le point de terminaison d'une API, c'est-à-dire une URL spécifique à laquelle une requête peut être envoyée pour déclencher une action (Fielding & Reschke, 2014).
F1-Score	C'est une métrique d'évaluation d'un modèle de classification qui est définie comme la moyenne harmonique de la précision et du rappel : $F1 = 2 \times (\text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel})$. Un score de 1 indique une classification parfaite (Breiman, 2001).
FastAPI	C'est un Framework Python moderne et performant pour le développement d'APIs web. Il se distingue par ses performances élevées, son typage fort via Pydantic ; la génération automatique de documentation OpenAPI et son support natif des opérations asynchrones (https://fastapi.tiangolo.com/).
Flutter	C'est un Framework développé par Google qui permet de créer des applications mobiles, web et desktop à partir d'un seul code source en utilisant le langage Dart. Il est apprécié pour sa rapidité et la fluidité des de ses interfaces (https://flutter.dev/).
Frontend	C'est la partie visible et interactive d'une application par l'utilisateur (https://aws.amazon.com/fr/compare/the-difference-between-frontend-and-backend/).
Gouvernance des données	C'est un ensemble des politiques, processus et responsabilités visant à garantir que les données d'une organisation sont gérées de façon sécurisée, cohérente et conforme aux réglementations applicables (Laudon & Laudon, 2020).
HTTPS	Il veut dire HyperText Transfer Protocol Secure. C'est la version chiffrée du protocole HTTP utilisant SSL/TLS pour garantir la confidentialité et l'intégrité entre un client et un serveur (Fielding & Reschke, 2014).
Human-in-the-loop	Il s'agit d'un principe de conception des systèmes d'IA qui maintient un être humain dans la boucle de décision. L'IA analyse, suggère et automatise, mais les décisions finales restent sous contrôle humain (Amershi et al, 2014).
IA générative	C'est une catégorie de systèmes d'intelligence artificielle capable de générer des contenus (textes, images, code, etc.) originaux à partir d'un prompt à l'exemple de GPT-4 ou Gemini.

IA spécialisée	C'est un système d'intelligence artificielle conçu pour un domaine ou une tâche précise à l'opposition de l'IA généraliste. Ses réponses sont ancrées dans une base de connaissance maîtrisée, ce qui garantit leur pertinence et leur vérifiabilité (Russell & Norvig, 2020) .
Incident de sécurité	C'est tout événement qui compromet ou menace la confidentialité, l'intégrité ou la disponibilité d'un système d'information ou des données qu'il contient à l'exemple d'une intrusion, d'un ransomware, d'une fuite de données ou d'un déni de service (Bhatt et al., 2014) .
Ingestion	C'est la phase initiale qui consiste à charger des documents, les découper en fragments (chunks), les transformer en embeddings et les indexer dans la base vectorielle dans le contexte RAG. Elle est réalisée une fois et mise à jour lors de l'ajout de nouveaux documents (Lewis et al., 2020).
Injection de prompt	C'est une technique d'attaque spécifique aux systèmes d'IA qui consiste à formuler une requête malveillante pour tromper l'agent et lui faire adopter un comportement prévu comme révéler des données confidentielles, ignorer ses instructions de sécurité ou exécuter des actions non autorisées (OWASP Top 10 LLM, 2023).
Intégrité	C'est une propriété de sécurité qui garantit que des informations n'ont pas été modifiées de façon non autorisée. C'est l'un des trois piliers de la sécurité de l'information avec la confidentialité et la disponibilité (Rose et al, 2020) .
JSON	Il signifie JavaScript Object Notation. C'est un format léger d'échange de données, lisible par les humains et facilement parsable par les machines. C'est aussi un standard de facto pour les échanges entre frontend et backend dans les architectures REST modernes (Fielding & Reschke, 2014).
JWT	Il veut dire Json Web Token. Il s'agit d'un standard ouvert (RFC 7519) pour la transmission sécurisée d'informations entre parties sous forme d'objet JSON signé numériquement (https://datatracker.ietf.org/doc/html/rfc7519).
Keycloak	C'est une solution open source de gestion des identités et des accès (IAM). Il implémente les protocoles OAuth2, OpenID Connect et SAML. Il permet aussi la gestion centralisée des utilisateurs, des rôles et des permissions (https://www.keycloak.org/).
LangChain	C'est un Framework Python open source pour le développement d'applications basées sur des modèles de langage. Il fournit des abstractions pour la construction de pipelines RAG, la gestion de la mémoire conversationnelle, l'intégration d'outils externes et l'orchestration d'agents (https://docs.langchain.com/oss/python/langchain/overview).
LLM	Il veut dire Large Language Model (Grand Modèle de Langage). C'est un modèle d'apprentissage automatique entraîné sur d'immenses corpus de textes, capable de comprendre et générer du langage naturel à l'exemple de GPT-4(OpenAI), Gemini(Google), Mistral(Mistral AI), Llama (Meta), (Russell & Norvig (2020)).
Log	C'est un fichier ou flux d'événements enregistrés par un système informatique : connexions, actions, utilisateurs, erreurs, transactions réseau, etc. L'analyse de logs est une activité fondamentale en cybersécurité pour détecter les comportements anormaux et reconstituer la chronologie d'un incident (Du et al., 2017) .
Middleware	C'est un composant logiciel intermédiaire qui s'interpose dans le traitement des requêtes pour effectuer des opérations transversales : authentification, journalisation, validation, compression.

Mistral 7B	Il s'agit d'un modèle de langage open source développé par Mistral AI (société française). Ses 7 milliards de paramètres lui permettent de délivrer d'excellentes performances tout en restant exécutable sur du matériel standard (Laudon & Laudon, 2020).
Nginx	C'est un serveur web et reverse proxy open source de haute performance. Il assure le point d'entrée unique du système en assurant la terminaison SSL, filtrant les requêtes malformées, redirigeant le trafic vers les services appropriés et masquant l'architecture interne (https://nginx.org/).
OAuth2	C'est un protocole d'autorisation standard (RFC 6749) permettant à une application d'accéder à des ressources protégées au nom d'un utilisateur, sans que celui-ci communique ses identifiants directement à l'application (https://datatracker.ietf.org/doc/html/rfc6749).
Ollama	C'est un outil open permettant de télécharger et d'exécuter des modèles de langage directement en local, sur l'infrastructure de l'organisation. Il supprime toute dépendance à des APIs cloud externes comme OpenAI, et garantit la confidentialité de données soumises au modèle (https://ollama.com/).
On-premise	C'est un mode de déploiement où les logiciels, données et traitements sont hébergés sur l'infrastructure physique de l'organisation elle-même par opposition au cloud public (Laudon & Laudon, 2020).
OpenID Connect	Il s'agit d'une couche d'identité construite au-dessus d'OAuth2 en permettant aux applications de vérifier l'identité d'un utilisateur et d'obtenir des informations de profil de base (https://auth0.com/fr/intro-to-iam/what-is-openid-connect-oidc).
OWASP	Il signifie Open Web Application Security Project. C'est une organisation internationale à but non lucratif qui produit des ressources gratuites sur la sécurité des applications web. Son Top 10 LLM recense les dix risques de sécurité les plus critiques pour les applications basées sur des modèles de langage (OWASP Top 10 for LLM Applications, 2023).
pgvector	C'est une extension open source pour PostgreSQL et permet de stocker des vecteurs directement dans une base de données relationnelles et d'effectuer des recherches de similarité vectorielle (https://cloud.google.com/discover/what-is-pgvector?hl=fr).
Pipeline RAG	C'est l'enchaînement des étapes techniques constituant le processus RAG : ingestion des documents, découpage en chunks, génération des embeddings, indexation dans la base vectorielle, puis à chaque requête, il y a la recherche de similarité, la construction du contexte et la génération de la réponse (Lewis et al., 2020)).
PostgreSQL	C'est un système de gestion de base de données relationnelle open source réputé pour sa robustesse, sa conformité aux standards SQL et son extensibilité via des extensions comme pgvector (https://www.postgresql.org/).
Précision	C'est la proportion des prédictions positives qui sont effectivement correctes en évaluation de modèles de classification. La précision est égale à $VP / (VP + FP)$, où VP = Vrais Positifs et FP = Faux Positifs. Une précision élevée signifie peu de fausses alarmes (Breiman, 2001).
Principe de moindre privilège	C'est un principe de sécurité selon lequel un utilisateur, un programme ou un système ne doit disposer que des droits strictement nécessaires à l'accomplissement de ses tâches (Rose et al., 2020).

Pydantic	C'est une bibliothèque Python de validation de données pour typage. Elle est intégrée à FastAPI et garantit que les données reçues par l'API sont conformes aux schémas attendus, prévenant ainsi les injections et les erreurs de traitement (https://techblog.deepki.com/pydantic-aka-le-gamechanger/).
Python	C'est un langage de programmation interprété, à typage dynamique, particulièrement populaire dans les domaines de la data science et de l'intelligence artificielle (https://aws.amazon.com/fr/what-is/python/).
RAG	Il signifie Retrieval-Augmented Generation (Génération Augmentée par la Recherche). C'est une technique combinant la recherche documentaire et la génération de texte : plutôt que de répondre uniquement à partir de ses paramètres, le modèle de langage reçoit en contexte des extraits pertinents issus d'une base documentaire (Lewis et al., 2020)).
Random Forest	C'est un algorithme d'apprentissage automatique qui combine plusieurs arbres de décision pour faire des prédictions plus fiables. Chaque arbre analyse les données différemment et le résultat final est une sorte de "vote majoritaire" entre tous les arbres. Plus il y a des arbres, plus la prédiction est robuste (https://www.ibm.com/fr-fr/think/topics/random-forest).
RBAC	Il veut dire Role-Based Access Control (Contrôle d'Accès Basé sur les Rôles). C'est un mécanisme d'autorisation qui attribue des droits d'accès en fonction du rôle de l'utilisateur plutôt qu'à titre individuel. Il simplifie aussi la gestion des permissions à grande échelle (Sandhu et al., 1996) .
React.js	C'est une bibliothèque Javascript Open Source développée par Meta pour la construction d'interfaces utilisateur web. Elle est basée sur le concept de composants réutilisables (https://react.dev/).
Registre de traitements	C'est un document obligatoire pour les organisations soumises au RGPD qui recense tous les traitements de données personnelles effectués. Il décrit pour chaque traitement la finalité, la base légale, les catégories de données, les destinataires, les durées de conservation et les mesures de sécurité (Article 30 du RGPD, 2016).
REST	Il signifie Representational State Transfer. C'est un style d'architecture pour les services web, basé sur les principes du protocole HTTP comme les ressources identifiées par des URLs, les opérations via les méthodes HTTP (GET,POST,PUT,DELETE), absence d'état côté serveur (Fielding & Reschke, 2014).
Reverse Proxy	C'est un serveur intermédiaire qui reçoit les requêtes des clients et les redirige vers les serveurs applicatifs appropriés, sans que les clients connaissent l'architecture interne (https://nginx.org/).
RGPD	C'est le Règlement Général sur la Protection des Données (Règlement UE 2016/679). Il est entré en vigueur le 25 mai 2018 et encadre la collecte, le traitement et la conservation des données personnelles des résidents européens. Il impose aussi aux organisations des obligations de transparence, de minimisation des données, de sécurité et respect des droits des personnes (Journal Officiel de l'Union Européenne).
Scikit-learn	C'est une bibliothèque Python Open source pour l'apprentissage automatique. Il fournit des implémentations efficaces de nombreux algorithmes de classification, régression, clustering et réduction de dimensionnalité (https://scikit-learn.org/stable/).
Security by Design	C'est une approche de développement logiciel qui intègre les exigences de sécurité dès la phase de conception, plutôt que de les ajouter a posteriori (Rose et al., 2020).

Système d'Information	C'est l' ensemble des ressources humaines, technologiques et organisationnelles mobilisées pour collecter, stocker, traiter et diffuser l'information nécessaire au fonctionnement d'une organisation. Il comprend les infrastructures réseau, les bases de données et les processus associés (https://www.sage.com/fr-fr/blog/glossaire/systeme-dinformation-definition/).
SSL/TLS	Il signifie Secure Sockets Layer/Transport Layer Security. Ce sont des protocoles cryptographiques assurant la confidentialité, l'intégrité et l'authenticité des communications sur Internet. TLS est le successeur de SSL (Fielding & Reschke, 2014).
Souveraineté des données	C'est le principe selon lequel les données d'une organisation restent sous son contrôle exclusif, hébergées sur son infrastructure propre, sans transit vers des services tiers ((Article 44-49 du RGPD, 2016).
TailwindCSS	C'est un Framework CSS utilitaire qui permet de styliser des interfaces web directement dans le HTML via des classes prédéfinies. Il favorise une approche composant-first et accélère le développement d'interfaces modernes (https://tailwindcss.com/).
Token	Dans le contexte d'authentification, c'est un jeton numérique qui prouve qu'un utilisateur a été authentifié et qui précise ses droits (https://datatracker.ietf.org/doc/html/rfc7519).
Traitement de données	Au sein du RGPD, il s'agit de toute opération ou ensemble d'opérations effectuées sur des données personnelles : collecte, enregistrement, organisation, conservation, consultation, utilisation, communication, diffusion, effacement et destruction (Article 4.2 du RGPD, 2016).
TypeScript	C'est un superset typé de JavaScript développé par Microsoft. Il ajoute un système de types statiques à Javascript, améliore la maintenabilité et réduit les erreurs à l'exécution (https://blog.cellenza.com/developpement-specifique/introduction-a-typescript/).
UML	Il signifie Unified Modeling Language (Langage de Modélisation Unifié). C'est un langage de modélisation standardisé par l'OMG qui permet de représenter visuellement la structure et le comportement d'un système logiciel. Il comprend une dizaine de types de diagrammes comme les diagrammes de cas d'utilisation, de séquence, de classes, d'activité et de déploiement (Russell & Norvig, 2020).
Vecteurs	C'est un tableau de nombres réels représentant un objet dans un espace mathématique de haute dimension (Lewis et al.,2020).
Vectorisation	C'est un processus de transformation d'un texte en vecteur via un modèle d'embedding. C'est une étape clé du pipeline RAG qui est réalisée à la fois lors de l'ingestion des documents et lors de chaque requête utilisateur (Lewis et al.,2020).
Zero Trust	C'est un modèle de sécurité formulé par John Kindervag (Forrester Research) qui repose sur le principe : "Ne jamais faire confiance, toujours vérifier". Aucune entité, utilisateur, machine ou application n'est considérée fiable par défaut, même à l'intérieur du réseau. Chaque accès est authentifié, autorisé et audité en continu (Kindervag, 2010).

LISTE DES TABLEAUX

1	Les parcours en Licence et Master	7
2	Comparaison des méthodes de collecte de données	14
3	Axes d'analyse et objectifs de validation	15
4	Répartition des classes du dataset CICIDS	16
5	Matrice des rôles et des permissions	19
6	Exigences non fonctionnelles du système	22
7	Justification des choix des outils	32
8	Tableau récapitulatif des labels et actions de surveillance	34
9	API d'authentification	48
10	API RGPD – Gestion des traitements et conformité	49
11	API Cybersécurité – Analyse des logs et événements	49
12	Métriques de classification sur le jeu de test	50
13	Correspondance entre les exigences de sécurité et les mécanismes techniques	51
14	Performances du modèle de classification	52
15	Résultats des tests fonctionnels	53
16	Résultats des tests de sécurité	54
17	Évaluation de la pertinence de l'agent RGPD	55
18	Rapport de classification du modèle	55
19	Performances mesurées du système	56
20	Évaluation du modèle de classification des événements de sécurité	56
21	Analyse des risques du projet	57
22	Estimation budgétaire du projet	58

LISTE DES FIGURES

1	Organigramme interne de CyberIntrust	3
2	Organigramme de l'INSI	5
3	Diagramme de Gantt du projet	17
4	Diagramme de cas d'utilisation	24
5	Diagramme de séquence Agent RGPD	25
6	Diagramme de séquence Agent Cybersécurité	26
7	Diagramme de classe – Modules Conversationnel et RGPD	27
8	Diagramme de classe – Application Cyber-Surveillance	28
9	Diagramme d'activité	30
10	Diagramme de déploiement	31
11	Schéma de l'architecture Web pour l'agent RGPD : Phase d'initialisation	34
12	Schéma de l'architecture Web pour l'agent RGPD : Phase d'interaction utilisateur	35
13	Schéma de l'architecture Web pour l'agent RGPD : Les propriétés garanties	35
14	Page de connexion	36
15	Page Dashboard du rgpd_web	36
16	Page Analyse Traitement dans rgpd_web	37
17	Page d'interaction avec l'agent RGPD	38
18	Historique des conversations avec l'agent RGPD	39
19	Architecture mobile de l'agent cybersécurité	39
20	Page de connexion de l'appli mobile Cybersécurité	40
21	Réinitialisation mot de passe	40
22	Dashboard Appli mobile agent _{cybersec}	41
23	Soumission de fichier log	42
24	Popup alerte de détection d'incidents critiques	42
25	Résultat des analyses d'un fichier log	43
26	En-tête du rapport PDF	44
27	Affichage des événements critiques	44
28	Affichage des événements suspects	45
29	Recommandations dans PDF	45
30	Architecture globale du système	47
31	Configuration Nginx sécurisée	.XVIII
32	Authentification JWT	.XVIII
33	Filtre de protection contre les injections de prompts	XIX
34	chargement en PDF des documents	XIX
35	Découpage des documents en fragments	XX
36	Génération des embedding via Ollama	XX
37	Indexation des vecteurs dans ChromaDB	XX
38	Recherche des fragments par similarité continue	XXI
39	Construction du prompt et génération de la réponse	XXII
40	Extracteur de features pour la classification des logs	.XXIII
41	Entraînement du modèle de classification	.XXIII

42	Structure du projet Flutter	XXIV
43	Stockage sécurisé du JWT de Flutter	XXV
44	Client HTTP Flutter avec gestion automatique du token	XXV

INTRODUCTION

Les grands modèles IA ne sont pas, pour le moment, à la hauteur des attentes des entreprises et des administrations. Le ROI, la fiabilité et les coûts de maintenance restent trop élevés. En attendant des améliorations de ces modèles, les entreprises suivent de très près l'IA Agentique pour améliorer leur productivité en adaptant leur procédure par hybridation. L'approche est plus pragmatique car elle s'appuie sur les piliers des SI de l'Entreprise constitués par les données et le référentiel documentaire (à priori plus fiable que les données sur lesquelles s'appuient les grands modèles d'IA), par les processus métier existants même si ces derniers doivent être revus en profondeur et, par les connaissances et expériences des collaborateurs concernant le secteur d'activité de l'entreprise.

L'objectif de ce projet a été de développer une solution intégrant un agent IA capable d'assister les utilisateurs dans le traitement des incidents afin d'améliorer l'efficacité des processus métiers. Le projet a abouti à la réalisation d'une application mobile développée avec Flutter ainsi qu'une interface web intégrant un chatbot intelligent.

La solution développée permet d'aider au diagnostic des incidents et à l'identification d'éventuels incidents de sécurité. Le développement a été réalisé en tenant compte des recommandations de sécurité de l'OWASP ainsi que des principes fondamentaux de l'IA Act européen afin de proposer une approche plus fiable et plus sécurisée.

Le périmètre du projet couvre une première version fonctionnelle de la solution, construite autour d'un cas d'usage concret intégrant un agent IA dans un processus métier hybride. La procédure est déclenchée lors de la réception d'un incident, intégré ou non à la plateforme développée.

Notre problématique est la suivante : « Comment une entreprise peut-elle intégrer des agents d'intelligence artificielle spécialisés au sein de son système d'information afin d'améliorer la performance des processus métiers et la gestion des incidents de cybersécurité, tout en garantissant la gouvernance des données, la sécurité du SI et le contrôle humain ? »

L'objectif principal est de proposer un modèle d'intégration d'agents IA dans le SI de l'entreprise. Pour y parvenir, la démarche s'articule autour de plusieurs objectifs spécifiques : D'abord, il est primordial d'identifier les limites des IA grands publics en entreprise et analyser les processus métiers possibles afin de définir un cadre de gouvernance des agents IA. Ensuite, il s'agira de modéliser un agent IA d'assistance métier dans le but d'évaluer les gains en performance et en sécurité.

Afin de développer notre travail, nous l'avons divisé en trois parties distinctes. Dans la première partie, nous allons entamer sur un cadre théorique et contextuel du projet en parlant de l'IA, le système d'information et la cybersécurité. Ensuite, nous allons entrer dans le cœur du projet à travers la conception de la solution qui comprend l'architecture et la modélisation du projet. Enfin, nous allons montrer la réalisation, les tests et une évaluation globale du projet dans la troisième partie.

I CONTEXTE GENERAL DU PROJET

Cette première partie établit les fondements conceptuels sur lesquels se construit l'intégralité de notre projet. Avant de proposer une solution, il convient de bien comprendre l'environnement dans lequel il s'inscrit : qu'est ce qu'un système d'information, quels défis les entreprises rencontrent-elles aujourd'hui et pourquoi l'intelligence artificielle dans une forme spécialisée et sécurisée représente-t-elle une réponse pertinente à ces défis ?

Tout d'abord, nous allons ouvrir le bal par une présentation du contexte opérationnel de l'entreprise d'accueil. Ensuite, nous enchaînons par les principes de base de l'intelligence artificielle agentique, tout en mettant en exergue les différences avec les assistants généralistes que nous connaissons tous. Enfin, nous aborderons les questions de sécurité que soulève l'intégration de cette technologie au centre d'un système d'information délicat.

I.1 Présentation de l'entreprise

I.1.1 Aperçu général

Créée en Juin 2024, Cyber In Trust est une entreprise spécialisée dans la fourniture de logiciels dédiés au RGPD et à la cybersécurité, ainsi que de services associés. Elle dispose d'un centre de développement logiciel situé en Métropole et sur l'île de la Réunion. En outre, c'est un développeur de solutions pour la conformité réglementaire (RGPD) et de cybersécurité, principalement axées sur l'approche ZERO TRUST et la Défense en profondeur.

Outre les logiciels, elle met à la disposition de ses clients un centre de services dédié au développement RUST, ainsi que des propositions de service en matière de sécurité informatique. Ici, le Zero Trust est une approche de cybersécurité qui repose sur le principe « ne jamais faire confiance, toujours vérifier ». Contrairement aux méthodes traditionnelles qui font confiance aux utilisateurs une fois qu'ils sont à l'intérieur du réseau, ce principe vérifie continuellement l'identité et les autorisations à chaque accès.


Parmi ses clients européens, nous pouvons citer :

- Le Ministère des Affaires Etrangères Français
- Le Conseil Européen de Bruxelles
- Le Groupe Up (c'est un éditeur de solutions de paiement et de services à fort potentiel de cohésion sociale et compte 60 clients)
- Un cabinet d'audit DCMF ou Déontologie & Compliance des Marchés Financiers
- Un cabinet de recrutement RGPD
- Le Ministère des Affaires Etrangères Français (compte une dizaine de clients)
- All Livres (vente de livres d'occasion en Normandie)

I.1.2 Organisation en interne

CyberIntrust adopte une structure à plat ou que l'on appelle structure organisationnelle horizontale" qui est caractérisée par une relation directe entre la direction et les membres productifs de l'équipe. Notons que ce modèle élimine les niveaux hiérarchiques intermédiaires où la frontière entre dirigeant et exécutant est volontairement réduite. Ici, chaque membre combine expertise technique et savoir métier dans une logique de responsabilisation individuelle (Figure 1).

En interne, CyberInTrust compte 5 employés distincts :



Source : CyberInTrust, 2026

FIGURE 1 – Organigramme interne de CyberInTrust

I.1.2.1 Direction Générale et Conception des systèmes CyberInTrust

En tant que Dirigeant et Concepteur principal, Jean-Pierre Bideau assure la vision stratégique de l'entreprise et assure la conception architecturale des systèmes CyberInTrust. Egalement, il supervise l'ensemble des activités orientées vers deux axes majeurs qui sont la conformité réglementaire et la cybersécurité augmentée par l'IA. Dans la feuille de route de l'entreprise, le conseil CRM actuellement en place sera remplacé d'ici Octobre 2026, avec une bascule complète vers CyberInTrust prévue en 2027.

I.1.2.2 Direction technique des développements

La place de Direction Technique des développements consiste à produire des documentations techniques, conseiller et orienter les choix technologiques. En parallèle, il intervient opérationnellement sur le développement RUST et l'administration des serveurs en assurant un lien fort entre la vision.

I.1.2.3 Responsable des Back Offices (Base de données et API)

Ce rôle couvre la gestion des bases de données et API, ainsi que la réalisation des tests pour valider le bon fonctionnement des modules développés. Il constitue le socle technique sur lequel reposent les autres développements en garantissant l'intégrité des données.

I.1.2.4 Développement React-JS, Python Agents IA

Ce rôle est au coeur de l'innovation produit. Il couvre le prototypage de l'application, notamment les modules constituant la base du système. Son périmètre s'étend au développement backend python incluant la conception et l'intégration des agents IA. Ce poste est crucial car il combine interface utilisateur et intelligence artificielle au service de la conformité et de la cybersécurité.

I.1.2.5 Développement React-JS RUST

L'utilisation du langage de développement RUST est privilégié pour ses performances et sa sécurité mémoire. Le développeur en charge assure la cohérence technique de la stack entre l'interface utilisateur et les composants bas niveau.

I.1.2.6 Responsable Prospection Validation des référentiels de données

Enfin, ce poste se charge du développement commercial de CyberInTrust à travers la prospection de nouveaux clients et partenaires. En outre, il joue un rôle structurant dans la validation des référentiels de données en garantissant que les données mobilisées par les systèmes IA sont fiables, conformes et correctement qualifiées.

Ainsi, nous pouvons dire que CyberInTrust est une équipe à taille humaine où chaque membre de l'équipe maîtrise

pleinement son domaine et participe directement au projet. Cette structure agile nous permet d'avancer vite, avec efficacité afin de répondre aux enjeux de conformité et de cybersécurité à l'ère de l'intelligence artificielle.

I.1.3 Domaine de spécialisation

Comme services, elle propose :

- un logiciel de cybersécurité Zero Trust qui réduit les accès au strict nécessaire et observe constamment les actions afin d'identifier des activités douteuses.
- des solutions de cybersécurité via un processus d'enrôlement facilitant la gestion des terminaux même depuis l'extérieur tel que la sécurité renforcée des transactions, la protection des données critiques, la traçabilité complète du système, la détection intelligente des anomalies et la gestion centralisée et réactive. Cette solution s'adresse au travail à distance, aux secteurs réglementés (application bancaire, logiciel de santé utilisé par les médecins, etc.), les données sensibles et les éditeurs de logiciels.
- un centre de Service SafeOnDesign qui place la sécurité et la conformité réglementaire au cœur du développement logiciel en s'appuyant sur trois technologies : Rust pour les applications critiques haute performance, Python pour l'analyse de données et l'automatisation rapide, JavaScript pour le Web moderne. Cette solution s'applique aux startups, aux PME et Grands Comptes et aux secteurs spécifiques (fintech, applications IoT, etc.)
- un Audit et Conseil qui évalue la sécurité des entreprises clientes et donne des recommandations sur mesure pour optimiser leurs défenses.

Leur mission principale est de réduire de manière drastique les risques d'exploitation en agissant sur les domaines réglementaires et de la sécurité des systèmes d'informations des entreprises.

Quant à leur perspective, elle s'inscrit dans une approche disruptive par rapport aux solutions existantes, CyberTrust croit qu'il faut fermer les portes d'entrées les plus utilisées par les attaquants externes en sécurisant les deux failles les plus exploitées qui sont l'authentification des appareils et des utilisateurs. Leur philosophie de sécurité par conception (SafeOnDesign) insiste sur le fait d'intégrer la protection dès le développement plutôt qu'en cours de route en liant physiquement chaque terminal à son identité numérique de manière infalsifiable.

I.2 Présentation de l'INSI

I.2.1 Information d'ordre général

INSI (Institut National Supérieur d'Informatique) est un institut universitaire situé à Antananarivo, spécialisé dans le domaine de l'informatique. Il accueille principalement des bacheliers ayant choisi cette filière, mais reste également ouvert à toute personne manifestant un intérêt particulier pour les métiers du numérique, à travers son centre de formation professionnelle.

L'établissement a été fondé le 17 août 2021 et son siège se trouve à Ankazotokana Ambanidia, Lot VF 32 Ter.

Pour tout renseignement, vous pouvez nous contacter par email à contact@insi.mg ou visiter notre site web : www.insi.mg

INSI bénéficie du soutien d'entreprises partenaires, dont Ilo Madagascar SARLU et Data Pulse Center, qui sont également à l'origine de sa création.

I.2.2 Missions et historiques

INSI a été fondée le 17 août 2021 à Antananarivo, dans un contexte marqué par une forte demande de compétences dans le domaine de l'informatique et des technologies numériques.

Créé à l'initiative de Ilo Madagascar SARLU et Data Pulse Center, l'Institut a vu le jour avec pour ambition de former une nouvelle génération de professionnels qualifiés, capables de répondre aux besoins du marché local et

international.

Depuis sa création, INSI ne cesse d'évoluer en adaptant ses formations aux enjeux technologiques actuels, tout en favorisant un apprentissage pratique, orienté vers les réalités du monde professionnel.

La mission principale de l'INSI est de former des experts compétents, éthiques et innovants dans le domaine de l'informatique, capables de contribuer activement au développement économique et numérique de Madagascar.


L'Institut s'engage à :

- Offrir des formations de qualité, à jour des évolutions technologiques,
- Favoriser l'insertion professionnelle de ses apprenants,
- Créer un lien fort entre la formation académique et les besoins réels des entreprises,
- Encourager l'entrepreneuriat et l'innovation technologique,

Contribuer à la démocratisation de l'accès au savoir numérique

I.2.3 Organigramme de l'INSI

La figure 2 représente la structure organisationnelle de l'INSI, mettant en évidence les différentes fonctions et responsabilités au sein de l'institut, ainsi que les liens hiérarchiques entre les divers services.



Source : INSI, 2026

FIGURE 2 – Organigramme de l'INSI

L'organigramme de l'INSI, en partenariat avec le Collège de Paris, est structuré autour d'une direction générale incarnée par le Président Directeur Général. Ce dernier assure la coordination de trois pôles principaux : la Direction Administrative et Financière, la Direction des Études, et le service des Relations Internationales et Mobilités.

Le Président Directeur Général assure la direction stratégique de l'institut. Il supervise l'ensemble des activités pédagogiques, administratives et de développement. Il veille à la qualité de l'enseignement, à la bonne gestion des ressources humaines et matérielles, et représente l'établissement auprès des partenaires et autorités.

La Direction Administrative et Financière est chargée de la gestion des affaires internes, notamment à travers deux services essentiels : le service des scolarités, qui s'occupe des dossiers étudiants, inscriptions et suivi académique, et les services supports et stratégiques, qui assurent un appui logistique, administratif et technologique à l'ensemble de l'institut.

Le pôle des Relations Internationales et Mobilités gère les échanges académiques avec l'étranger ainsi que les projets de mobilité étudiante ou enseignante.

La Direction des Études supervise quant à elle l'ensemble des programmes pédagogiques et le corps enseignant. Elle travaille en étroite collaboration avec un Responsable Parcours, qui coordonne les différentes spécialisations proposées. Cette direction intègre également une cellule dédiée à la formation professionnelle et à la certification, en charge des dispositifs de validation des compétences, des certifications professionnelles et des parcours de formation continue. Il comprend également le Département alternance et emplois, responsable du suivi des étudiants en contrat d'alternance, des stages professionnels, et de l'insertion professionnelle.

Sous la partie Responsable Parcours, plusieurs responsables pédagogiques gèrent les différentes filières de formation : le parcours tronc commun, qui regroupe les matières fondamentales partagées par tous les étudiants en début de cycle ; le parcours ARS IC ; le parcours GL BDD ; et enfin le parcours IAD I2AD.

D'autres structures, bien que non représentés sur cet organigramme, contribuent également de manière significative à la mission de l'INSI.

Le Conseil de l'École, Il regroupe des membres de l'équipe pédagogique et administrative. Il joue un rôle consultatif ou décisionnel sur les questions académiques : validation des programmes, suivi des résultats, discipline, méthodologie, etc.

Le responsable de la formation en ligne, Il conçoit et supervise les dispositifs d'apprentissage à distance. Il s'assure que les contenus en ligne sont accessibles, interactifs et conformes aux standards pédagogiques, tout en accompagnant enseignants et étudiants dans leur utilisation.

L'Association et Clubs étudiants, encadre et soutient les initiatives étudiantes, les clubs thématiques (informatique, innovation, sport, culture, etc.), et les événements organisés dans le cadre de la vie étudiante. Cela favorise l'engagement, le développement personnel et les compétences transversales des étudiants.

Cette structure témoigne d'une organisation à la fois pédagogique, administrative et tournée vers l'international et l'employabilité, assurant une formation complète et professionnalisante aux étudiants.

I.2.4 Domaine de spécialisation

INSI propose des parcours académiques professionnalisants dans le domaine de l'informatique et des technologies numériques, articulés autour de licences professionnelles, de masters spécialisés, formations professionnelles continues et d'opportunités de mobilité internationale.

I.2.4.1 Licences professionnelles

Les programmes de licence offrent une formation de base solide, axée sur la pratique, et préparant à une insertion rapide dans le monde professionnel : GL (Génie Logiciel) : Conception, développement et maintenance d'applications logicielles. ARS (Administration Réseaux et Systèmes) : Gestion d'infrastructures informatiques, réseaux, serveurs et systèmes. IAD (Intelligence Artificielle et Data Science) : Introduction aux algorithmes d'IA, au traitement de données et à l'apprentissage automatique.

I.2.4.2 Masters professionnels

Les masters permettent d'approfondir les compétences techniques et managériales, en lien étroit avec les évolutions du secteur : GL (Génie Logiciel et Base de Données) : Pilotage de projets numériques, gouvernance des SI. IC (Infrastructures et Cybersécurité) : Sécurisation des systèmes, audit, réseaux avancés. I2AD (Intelligence Artificielle, Analyse de Données et Automatisation) : Applications avancées de l'IA, automatisation des processus et science des données.

I.2.4.3 Formations professionnelles

INSI propose également des formations professionnelles continues, spécifiquement conçues pour les professionnels déjà en poste souhaitant approfondir leurs compétences ou se spécialiser dans l'un des domaines proposés. Ces formations sont adaptées aux contraintes des professionnels (horaires flexibles, modules pratiques) et visent à renforcer leur employabilité ou à accompagner leur évolution de carrière.

I.2.4.4 Mobilité internationale double diplôme

Dans une optique d'ouverture et de reconnaissance internationale, INSI propose à ses étudiants des opportunités de mobilité académique et de double diplôme, à partir de la deuxième année (L2).

- Format hybride : 6 mois de formation à Madagascar + 6 mois à l'étranger selon le parcours choisi.
- Double diplôme en L3 ou M2 : En partenariat avec des institutions internationales telles que : Collège de Paris (France), Keyce Informatique (France), Eskills (Québec, Canada)
- Conditions d'éligibilité : Niveau DALF C1 en français pour la mobilité vers des pays francophones tandis que Niveau B2 ou C1 en anglais pour les destinations anglophones.

I.2.5 Architectures des formations pédagogiques

Le recrutement des étudiants à l'INSI s'effectue exclusivement par sélection de dossiers pour l'entrée en première année de Licence (L1), et par voie de concours pour l'admission en Master 1. Au sein de l'INSI, une seule mention est proposée : Informatique, déclinée en trois parcours distincts aux niveaux Licence et Master (Tableau 1) :

TABLEAU 1 – Les parcours en Licence et Master

Niveau	Filière
Licence	Génie Logiciel et Base de Données
Master	Génie Logiciel et Base de Données
Master	Administration Réseaux, Systèmes
Master	Infrastructures et Cybersécurité (IC)
Master	Intelligence Artificielle et Data Science (IAD)
Master	Intelligence Artificielle, Analyse de Données et Automatisation (I2AD)

Source : INSI, 2026

L'architecture des études à trois niveaux conformément au système LMD (Licence Master et Doctorat) permet les comparaisons et les équivalences académiques des diplômes au niveau international. L = Licence (Bac + 3) = L1, L2, L3 = 6 semestres S1 à S6 10 M = Master (Bac + 5) = M1, M2 = 4 semestres S7 à S10

Le diplôme de licence est obtenu en 3 années des études après Baccalauréat. Et le diplôme de Master est obtenu en 2 ans après obtenu du diplôme de LICENCE. Le MASTER PROFESSIONNEL est un diplôme destiné à la recherche emploi au terme des études.

Spécificités pédagogiques

- École d'alternance dès la L2 S4
- Alternance cours/entreprise pour une meilleure insertion
- Écoles connectées e-learning
- Plateforme numérique de formation, cloud intégré, Google Workspace
- Cours accessibles en ligne selon les parcours

- Pédagogie active par projets
- Hackathons, soutenances exposées, projets réels en entreprise

I.2.6 Relations de l'INSI avec les entreprises et les organismes

L'Institut National Supérieur en Informatique (INSI) entretient des liens étroits avec le monde professionnel. L'INSI collabore activement avec de nombreux organismes publics, semipublics et privés, tant au niveau national qu'international. Cette collaboration se traduit concrètement par l'organisation régulière de stages obligatoires pour les étudiants, favorisant leur immersion professionnelle et leur employabilité.

Parmi les entreprises et institutions partenaires accueillant nos étudiants en stage chaque année, on peut citer : Data Pulse Center, RELIA Consulting, Code Talent, Bocasay, Minimad, Smartone AI, NOVITY, Eclasia Madagascar, VISEO Groupe, Océane Trade, ACCES Banque.

En plus des stages, l'INSI organise régulièrement des visites pédagogiques, des rencontres métiers et des projets collaboratifs avec plusieurs entreprises du secteur technologique et numérique. Ces activités permettent aux étudiants de mieux comprendre les réalités du terrain, d'échanger avec des professionnels et de s'ouvrir à l'environnement entrepreneurial. Parmi les entreprises ayant accueilli ces initiatives : NOVITY, YAS Madagascar, Smartone AI, Eclasia Madagascar, et d'autres acteurs majeurs du numérique à Madagascar. Cette dynamique de partenariat permanent constitue un pilier de la pédagogie à l'INSI, en lien avec son objectif de former des professionnels compétents, opérationnels et ancrés dans les besoins du marché.

I.2.7 Partenariat au niveau international

L'INSI s'est inscrit dans une dynamique d'ouverture à l'international grâce à son partenaire fondateur, ILO Madagascar, représentant de l'Organisation Internationale du Travail. Cette orientation se renforce aujourd'hui à travers des partenariats stratégiques avec des institutions académiques et des entreprises internationales, permettant à l'Institut de proposer une formation alignée sur les standards mondiaux.

L'INSI bénéficie actuellement de programmes de co-diplomation et de double diplôme en collaboration avec plusieurs établissements internationaux de renom, tels que :

- Collège de Paris International
- Keyce Informatique (France)
- Eskills Academy (Québec, Canada)
- École Supérieure Polytechnique d'Antsiranana (ESPA) – pour une synergie régionale renforcée.

Ces partenariats permettent non seulement d'enrichir l'offre pédagogique, mais aussi d'ouvrir des perspectives de mobilité académique et professionnelle aux étudiants, en leur offrant une reconnaissance de leurs compétences à l'échelle internationale.

Par ailleurs, à travers les stages annuels et projets pédagogiques, l'INSI collabore également avec des entreprises à dimension régionale ou mondiale, telles que :

- VISEO Groupe
- Eclasia Madagascar (Groupe mauricien)
- Smartone AI
- NOVITY, entre autres.

Ces relations actives témoignent de l'ancrage de l'INSI dans un écosystème global, plaçant l'Institut comme un acteur majeur de la formation en informatique à Madagascar, tourné vers l'innovation et les exigences du marché international.

I.2.8 Parcours professionnels des diplômés

Les diplômés de la Licence en Informatique de l'INSI disposent d'un socle solide de compétences en programmation, systèmes, réseaux, bases de données et développement logiciel. Cette polyvalence leur permet d'intégrer directement le marché du travail ou de poursuivre en Master. À ce niveau, ils peuvent exercer en tant que :

- Technicien système et réseau
- Développeur web / mobile (front-end ou back-end)
- Administrateur systèmes junior
- Technicien support IT
- Intégrateur / testeur logiciel
- Assistant en sécurité informatique
- Assistant en projets d'IA ou de data (selon profil)

Les stages annuels en entreprise leur offrent une première expérience professionnelle valorisante dans des structures variées : entreprises technologiques, banques, administrations, startups, ONG, etc.

La formation de Master proposée à l'INSI, grâce à ses parcours spécialisés, forme des professionnels capables d'intervenir sur des projets complexes, innovants et à dimension stratégique. Les débouchés varient selon la spécialisation choisie :

Parcours Ingénierie logicielle, réseaux et systèmes :

- Ingénieur en développement logiciel / full-stack
- Architecte logiciel
- Ingénieur systèmes et réseaux
- Administrateur cloud / DevOps
- Chef de projet informatique

Parcours Cybersécurité :

- Expert en sécurité des systèmes d'information
- Analyste SOC / CERT
- Auditeur en cybersécurité
- Responsable de la sécurité IT (RSSI)

Parcours Intelligence Artificielle et Data :

- Data Scientist
- Data Analyst
- Ingénieur en Intelligence Artificielle
- Machine Learning Engineer
- Développeur d'applications intelligentes
- Consultant en IA
- Spécialiste en traitement automatique du langage naturel (TALN)
- Spécialiste en vision par ordinateur (Computer Vision)

Grâce aux partenariats internationaux et aux projets en entreprise, les diplômés du Master peuvent également prétendre à des postes dans des structures multinationales, ou poursuivre une carrière académique et de recherche (doctorat, enseignement supérieur).

I.2.9 Ressources humaines

L'INSI s'appuie sur une équipe pédagogique et administrative compétente, dynamique et engagée dans la réussite de ses étudiants. Ses ressources humaines se répartissent comme suit :

- Président Directeur de l'INSI : Monsieur RAMASONDRANO Andriamanjaka, Docteur Ingenieur
- Responsable parcours ARS IC : Monsieur RATIANARISON Hery Mampionona,
- Responsable parcours tronc commun : Monsieur RAKOTONDRAMANANA R, Sitraka, Docteur Ingénieur
- Responsable parcours GL BDD : Mr ANDRIAMIADANA Tantely Antoine
- Responsable parcours IAD I2AD : par intérim PDG
- Nombres des enseignants : 40
- Nombres des personnels administratives : 04
- Personnels d'appui : 6

I.3 Identification du projet

I.3.1 Contexte et problématique

I.3.1.1 L'intelligence artificielle agentique : fondements et spécificités

a) IA générative et IA spécialisée

Actuellement lorsque nous parlons d'intelligence artificielle, nous pensons souvent aux assistants virtuels largement utilisés tels que ChatGPT ou Gemini [4]. Ces outils se distinguent par leur aptitude à produire du texte, à répondre à des interrogations générales ou encore à synthétiser des documents. Ils sont dits génératifs car ils génèrent des réponses basées sur un apprentissage effectué à partir de milliards de textes provenant du web. Cependant, cette généralité constitue également leur principal handicap dans un environnement professionnel. Par exemple, un assistant généraliste n'est pas informé des politiques internes d'une société, n'a pas accès à son registre de traitements et ne peut assurer la conformité de ses réponses aux exigences réglementaires d'un domaine spécifique. Aussi, il est encore plus préoccupant de confier des informations délicates à un service externe car cela pose des questions justifiées relatives à la souveraineté et à la confidentialité. C'est pourquoi notre projet ne se repose pas sur l'IA générative classique, mais sur une approche radicalement différente : celle des agents IA spécialisés.

Par définition, un agent spécialisé est un système d'intelligence artificielle conçu pour un domaine précis, qui puise ses réponses dans une base de connaissance maîtrisée et dont le comportement est contrôlé et vérifiable. Notons que les réponses qu'il génère ne sont pas fictives, elles se basent sur des informations réelles, vérifiables et propres à l'organisation.

b) Qu'est ce qu'un agent IA ? Définition et architecture

Un agent d'intelligence artificielle est un programme capable de percevoir son environnement, d'analyser les informations à sa disposition et de réagir en fonction pour accomplir un but précis. Dans notre contexte, cela signifie concrètement : recevoir une requête d'un utilisateur, interroger une base de connaissances et formuler une réponse appropriée et contextualisée. Cependant, un agent IA se démarque d'un chatbot classique grâce à son aptitude à mener plusieurs phases de réflexions consécutives. Par exemple, il est capable de reconnaître que la question posée traite d'un traitement de données spécifiques d'extraire les informations pertinentes de la base documentaire, de confronter ces informations avec les règles RGPD en vigueur, puis de formuler une réponse organisée.

Cette procédure peut s'effectuer en quelques secondes, contrairement à un analyste humain qui aurait besoin de plusieurs minutes. Il est à noter que dans notre structure, chaque agent est affecté à un domaine professionnel spécifique : il possède sa propre base de connaissance, son propre contexte d'exécution, et de droits d'accès strictement définis [6]. Cette séparation est fondamentale pour assurer la pertinence des réponses tout en protégeant les données traitées.

I.3.1.2 Les défis actuels : la conformité, les volumes et les menaces de cybersécurité

Aujourd'hui, les organisations subissent une triple pression. Tout d'abord, il y a la contrainte législative : le Règlement Général sur la Protection des Données (RGPD), entré en vigueur en 2018, impose aux entreprises des obligations strictes concernant la collecte, le traitement et la conservation des données personnelles. En cas de non conformité, des amendes pouvant aller jusqu'à plusieurs millions d'euros sont possibles, et le nombre de contrôles effectués par la CNIL se multiplient.

Ensuite, il y a la tension liée à l'ampleur des données : les entreprises produisent et utilisent des masses d'informations de plus en plus considérables. Il arrive souvent que des équipes responsables de la conformité, de la sécurité ou de la gestion des risques se trouvent souvent submergées par la masse de documents, de signalements et de demandes à traiter.

Enfin, les attaques numériques ont grandement évolué en termes de sophistication ces dernières années face à la montée des cybermenaces. Les incidents de sécurité tels que les ransomware, phishing ciblé et les intrusions dans les systèmes critiques sont désormais une réalité pour un grand nombre d'organisations. Par conséquent, il est crucial que les équipes de cybersécurité analysent des logs et d'alertes pour identifier les comportements anormaux, généralement dans un laps de temps restreint.

Compte tenu de ces défis, il est à noter que notre projet s'inscrit précisément dans ce cadre : des agents d'intelligence artificielle aptes à soutenir les équipes métiers de manière précise, fiable et sécurisée.

a) Conformité réglementaire : RGPD et IA Act

Notre solution opère dans un environnement réglementaire particulièrement rigoureux.

D'un côté, le RGPD pose des règles claires sur la façon dont les organisations collectent, utilisent et conservent nos données personnelles.

D'un autre, l'IA Act Européen vient compléter ce cadre [2] en s'attaquant à un angle mort jusqu'ici ignoré : les systèmes d'intelligence artificielle eux-mêmes. C'est la première fois qu'une réglementation leur est dédiée et son principe repose sur les strictes exigences qui s'appliquent sur les risques présentées par l'IA. Nos choix techniques sont orientés par plusieurs principes en conformité avec le RGPD.

Il est essentiel de noter que les agents IA ne transmettent jamais les données qu'ils manipulent en dehors de l'infrastructure de l'organisation d'où l'utilisation d'un modèle de langage localisé répond précisément à ce besoin et les accès sont enregistrés et soumis à audit. Et la période de rétention des données d'interaction est strictement limitée à ce qui est essentiel.

En ce qui concerne l'AI Act, nos agents sont classés comme systèmes à risque faible ou modéré en fonction de leur utilisation. Nous faisons en sorte que les utilisateurs soient toujours conscients qu'ils dialoguent avec un système automatisé et que les suggestions générées demeurent sous contrôle humain. Non seulement cette transparence est une exigence légale, mais elle représente également un élément crucial pour instaurer la confiance nécessaire à l'adoption réussie de l'instrument.

I.3.2 Objectifs du projet

Le projet vise trois objectifs principaux à savoir :

- Améliorer les processus métiers RGPD : il s'agit de réduire le temps consacré à la saisie des données, améliorer la fiabilité des analyses de conformité et de faciliter la production de documents réglementaires comme les fiches traitement et les analyses d'impact
- Renforcer la capacité de détection des incidents de cybersécurité en automatisant l'analyse des journaux système, en priorisant les analyses des événements selon leur niveau de criticité et en permettant une réactivité accrue des équipes terrain grâce à des alertes en temps réel et mobile sur terminal mobile

- Garantir la sécurité et la gouvernance du système sans transferts de données vers des services extérieurs et respecter le principe Zero Trust, du moindre privilège et du contrôle humain.

I.3.3 Intérêt et justification du projet

L'intérêt de ce projet est d'autant plus opérationnel que stratégique. En effet, la solution apporte un gain de temps et de fiabilité mesurable pour les équipes qui traitent quotidiennement des demandes de conformité ou des alertes de sécurité.

Sur le plan stratégique, ce projet permet à l'entreprise de se positionner comme un acteur innovant dans l'adoption responsable de l'intelligence artificielle, notamment dans les domaines de la cybersécurité et de la conformité.

En outre, sur le plan académique, il nous montre comment des approches modernes de l'intelligence artificielle comme le RAG et la classification automatique peuvent être appliqués à des problématiques professionnelles réelles et apporter des solutions concrètes aux besoins de l'entreprise.

I.3.3.1 Positionnement de ce travail par rapport à l'état de l'art

L'analyse de la littérature met en évidence plusieurs limites.

D'une part, la plupart des travaux se focalisent exclusivement sur les performances des algorithmes (telles que la précision, le rappel et le F1-score), sans considérer les contraintes opérationnelles concrètes comme le déploiement on-premise, le temps de latence ou l'adaptation à un système d'information existant.

Par ailleurs, rares sont les travaux qui offrent une solution complète alliant détection des anomalies, interface conçue pour les analystes sur le terrain et protection des agents IA (protection contre les injections, isolation des données, contrôle des accès). En ce qui concerne l'agent RGPD, l'approche RAG pour aider à la conformité est encore peu étudiée. Effectivement, la plupart des recherches reposent sur des LLM généralistes, sans véritables fondements dans la base documentaire réglementaire propre à l'entreprise.

I.3.3.2 Les deux agents de la plateforme comme entités autonomes

Dans ce travail de recherche, la plateforme conçue met en œuvre deux agents IA distincts, chacun présentant les caractéristiques agentiques mentionnées précédemment. Leur structure respective est expliquée en suivant le paradigme perception → décision → action.

a) Agent 1 — Agent RGPD (module web)

Ce premier agent réalise les missions suivantes :

- Perception : l'agent reçoit une interrogation ou une requête d'un utilisateur (DPO, responsable du traitement) par le biais de l'interface web, ainsi que le contexte documentaire indexé dans la base vectorielle.
- Décision : l'agent fait appel au pipeline RAG pour récupérer les extraits documentaires pertinents, avant de soumettre la question enrichie au LLM local en vue de produire une réponse contextualisée. Il juge la pertinence de la réponse avant de l'envoyer.
- Action : l'agent fournit à l'utilisateur une réponse organisée, crée si besoin un dossier de traitement complet, ou indique le manque de pertinence du contexte documentaire disponible.

Le but est d'optimiser la pertinence et le respect des réglementations dans les réponses tout en protégeant la confidentialité des informations de l'entité.

b) Agent 2 — Agent Cybersécurité (module mobile)

Quant au second agent, il effectue les missions suivantes :

- Perception : l'agent reçoit un dossier de journaux transmis par un analyste à travers l'application mobile et le déchiffre pour en tirer les événements individuels.
- Décision : pour chaque incident, l'agent utilise le processus de classification afin d'attribuer un degré de gravité. Il met alors en œuvre des règles de corrélation temporelle afin d'identifier des modèles d'attaque naissants qui auraient pu être négligés par la classification individuelle.
- Intervention : l'agent fournit à l'analyste un compte rendu organisé, lance une alerte push en cas de détection d'un événement critique et consigne les résultats dans l'historique pour future analyse.

Contrairement au premier agent, celui-ci a pour but d'optimiser le taux de repérage des incidents de sécurité effectifs tout en réduisant la charge mentale de l'analyste.

c) Taxonomie et positionnement des agents

D'après la classification de Wooldridge et Jennings (1995), les deux agents présents sur la plateforme se rangent dans le groupe des agents hybrides : ils fusionnent un aspect réactif (réaction instantanée aux entrées) et un aspect délibératif (analyse d'un contexte accumulé pour l'appariement d'événements et la création de réactions contextualisées). L'agent RGPD privilégie le côté délibératif en raison de la nécessité du raisonnement contextualisé dans son rôle, alors que l'agent cybersécurité met l'accent sur une réponse rapide pour répondre à l'exigence de traitement en moins de trente secondes.

I.4 Méthodologie

Dans ce mémoire, la méthodologie adoptée repose sur une démarche mixte qui assemble analyse documentaire, observation des systèmes en production et une comparaison empirique des approches techniques. Notre choix s'explique par la nature informatique du projet à savoir : la validation d'un système de sécurité et d'intelligence artificielle qui s'appuie sur des données objectives mesurables, logs réseau annotés, métriques de classification et des tests de conformité.

I.4.1 Méthode d'analyse et collecte des données

I.4.1.1 Choix de la méthode de collecte

Afin de recueillir les données nécessaires à la validation de nos hypothèses, nous avons examiné plusieurs options méthodologiques. A cela s'illustre la synthèse des avantages et inconvénients de chaque approche envisagée par le tableau 2.

TABLEAU 2 – Comparaison des méthodes de collecte de données

Méthode	Avantages	Inconvénients
Questionnaire / Entretien terrain	Recueil direct des besoins utilisateurs ; compréhension des usages réels.	Difficulté d'accès aux équipes techniques ; résultats subjectifs peu généralisables en sécurité.
Observation participante	Données objectives sur les incidents réels en production.	Accès limité aux environnements sensibles ; non reproductible.
Analyse documentaire + dataset public (CICIDS2017)	Données standardisées, volumineuses et reproductibles ; validation scientifique possible.	Données pas spécifiques à l'entreprise ; nécessite un prétraitement rigoureux.

Source : Auteure, 2026

Il est à noter que nous avons choisi l'analyse documentaire et le dataset public CICIDS2017 pour le module cybersécurité ainsi que l'analyse des documents réglementaire internes (politiques RGPD, guides CNIL, etc.) pour le module RGPD. En outre, le choix de cette méthode nous a permis de :

- garantir la reproductibilité des expériences et la comparabilité avec les travaux académiques existants,
- évaluer les performances du modèle de classification sur un jeu de données reconnu par la communauté scientifique
- éviter les biais liés à un échantillon terrain trop restreint à une seule organisation

I.4.1.2 Périmètre de l'étude et calcul de la taille d'échantillon

Pour déterminer la représentativité statistique de notre jeu de test, nous avons appliqué la formule de calcul de la taille d'échantillon pour une population finie. Ici, le corpus de départ (CICIDS2017) comprend $N = 2830$ événements de logs annotés. Voici la formule :

$$n = \frac{N}{1 + N \times e^2} \text{, où :}$$

n = taille de l'échantillon requis N = taille de la population ($N = 2830$ événements) e = marge d'erreur retenue (soit 5% compte tenu de l'exigence de fiabilité en cybersécurité)

Nous pouvons le calculer comme ceci :

$$\begin{aligned}
 n &= \frac{2830}{1 + 2830 \times 0,05^2} \\
 &= \frac{2830}{1 + 2830 \times 0,0025} \\
 &= \frac{2830}{1 + 7,075} \\
 &= \frac{2830}{8,075} \\
 &\approx 350 \text{ événements}
 \end{aligned}$$

Il faut noter que nous avons analysé 500 cas réels, qui est beaucoup plus que le minimum que nous nous sommes fixés (350). Ainsi, nous pouvons dire que nos résultats sont solides. Egalement, notre mélange de cas (normaux, suspects, critiques) est le même que celui que nous croisons toujours au travail. Ainsi, nous pouvons faire confiance à ces tests par la suite.

I.4.1.3 Axes d'analyse retenus

Pour un peu plus de clarté, nous avons divisé notre analyse en trois grandes parties où chaque étape vient vérifier un point précis de notre projet (Tableau 3).

TABLEAU 3 – Axes d'analyse et objectifs de validation

Axe	Thématique	Objectif de validation
Axe 1	Conformité RGPD des traitements	Valider la pertinence des réponses de l'agent RGPD sur des cas de traitement réels.
Axe 2	Détection d'anomalies dans les logs	Mesurer la précision du classificateur Random Forest sur les 500 événements de test.
Axe 3	Besoins fonctionnels des utilisateurs	Confronter les fonctionnalités développées aux cas d'usage identifiés sur le terrain.

Source : Auteure, 2026

I.4.1.4 Analyse des résultats par axe

a) Axe 1 - Conformité RGPD :

Nous avons mis notre agent RGPD à l'épreuve avec 30 questions clés sur les obligations majeures (droits des utilisateurs, transferts des données hors UE, etc.). Par conséquent, le résultat est très encourageant : dans près de 9 cas sur 10 (soit 86,7%), l'agent a non seulement donné la bonne réponse, mais il a aussi cité précisément les articles et lois concernées. Ainsi, ceci prouve que notre technologie (le système RAG) fonctionne parfaitement pour transformer une base de documents complexes en une aide juridique concrète et fiable.

b) Axe 2 - Détection d'anomalies :

Quant à notre modèle d'IA (Random Forest), il a été testé sur 500 événements réels et affiche un excellent score de 92% de réussite. Par contre, on note une petite hésitation sur les cas dits "suspects" (90%), ce qui est logique car la frontière entre un comportement normal et une menace est parfois floue, même pour un expert humain.

c) Axe 3 - Besoins fonctionnels :

Enfin, nous avons vérifié que l'outil fait bien tous ce que les utilisateurs nous avait demandé (analyse, chat, lecture de logs, tableau de bord). Toutes les fonctionnalités prioritaires sont non seulement présentes mais elles passent les tests avec succès.

I.4.2 Méthode d'analyse retenue et données de traitement

Pour réaliser ce projet, nous avons combiné plusieurs méthodes : entretien avec notre employeur et analyse de documents. Etant donné que nous travaillons au sein de l'entreprise, nous faisons des réunions régulières pour comprendre le fonctionnement du traitement des dossiers RGPD et l'analyse des alertes de sécurité, afin d'identifier les difficultés et les pistes d'amélioration. Ensuite, nous avons mené des entretiens avec notre employeur qui est la personne la mieux concernée pour comprendre le rôle des différents acteurs tels que le DPO et les analystes en cybersécurité. Enfin, nous avons complété ce travail par une analyse des textes réglementaires, des référentiels de sécurité et de la documentation technique liée aux technologies utilisées.

I.4.2.1 Dataset utilisé : CICIDS2017

A priori, le modèle de classification a été entraîné et évalué en utilisant le CICIDS2017 (Système de Détection d’Intrusion du Canadian Institute for Cybersecurity 2017) [5], fourni par l’Université du Nouveau-Brunswick. Ce jeu de données est une référence dans la communauté de détection d’intrusion et offre plusieurs atouts majeurs pour cette tâche dans le Tableau 4 ci-après.

- Plus de 2,8 millions d’incidents réseau ont été enregistrés dans un contexte contrôlé et réaliste. Le contenu comprend des cas d’étude sur 14 formes d’attaques contemporaines : DoS, DDoS, Brute Force, XSS, Injection SQL, Infiltration, Botnet, Portscan.
- Il est ouvertement disponible et couramment employé comme référence, facilitant une comparaison directe avec les projets existants.
- Chaque entrée est étiquetée avec une désignation d’attaque spécifique ou la classe BENIGN, offrant ainsi un apprentissage supervisé strict.

TABLEAU 4 – Répartition des classes du dataset CICIDS

Classe finale	Classe CICIDS source	Volume (approx.)	Proportion
NORMAL	BENIGN	2 359 087	83.6%
SUSPECT	PortScan, Bot, Infiltration	312 545	11.1%
CRITIQUE	DoS, DDoS, BruteForce, SQLi, XSS	150 867	5.3%

Source : Auteure, 2026


I.4.2.2 Prétraitement et feature engineering

Avant l’entraînement, les données brutes ont été soumises à un processus de prétraitement en cinq phases à savoir :

- Le nettoyage : élimination des doublons, gestion des valeurs absentes (remplissage par la médiane pour les attributs numériques et par le mode pour les attributs catégoriels), ainsi que suppression des colonnes dont la variance est nulle.
- La normalisation : les caractéristiques numériques ont été normalisées via l’utilisation du z-score afin d’éviter que les caractéristiques de grande ampleur ne prennent le pas sur les autres durant le processus d’entraînement. L’encodage one-hot a été utilisé pour coder les caractéristiques catégorielles.
- La sélection de caractéristiques : sur les 80 caractéristiques présentes dans le CICIDS2017, 23 ont été choisies suite à l’évaluation de la corrélation et de l’importance des variables, basée sur un Random Forest initial. Notons que les features les plus discriminantes sont : la durée du flux, le nombre total de paquets envoyés, la moyenne de la longueur des paquets transmis, le débit en octets par seconde du flux, la moyenne de l’intervalle entre les paquets du flux et les indicateurs TCP (Transmission Control Protocol).
- La gestion du déséquilibre de classes : nous avons utilisé la méthode SMOTE (Synthetic Minority Over-sampling Technique) [3] sur les classes minoritaires (SUSPECT et CRITIQUE) afin d’harmoniser les proportions dans le jeu d’apprentissage. En principe, cette méthode produit des exemples synthétiques dans l’espace des caractéristiques au lieu de reproduire des exemples préexistants, ce qui favorise la généralisation.
- La segmentation des données : le jeu de données a été fractionné en trois parties en suivant une stratification par catégorie afin de maintenir.

I.4.3 Planning et chronogramme de réalisation

La Figure 3 démontre que le projet s’est déroulé sur une période de huit semaines qui sont découpées en quatre grandes phases : analyse (semaine 1 et 2), conception (semaine 3 et 4), développement (semaine 5 et 6), tests et rédaction (semaine 7 et 8) . La Figure 3 présente le diagramme de Gantt synthétique du projet.



Source : Auteurs, 2026

FIGURE 3 – Diagramme de Gantt du projet

II ANALYSE ET CONCEPTION

Après avoir posé les bases théoriques qui justifient notre démarche, nous entamons à présent la phase de conception. Cette deuxième partie représente l'essence même de notre travail d'ingénierie : elle explique comment nous avons transformé une problématique métier complexe en une solution technique ordonnée, structurée et sécurisée. Nous commencerons par un examen détaillé des besoins repérés dans le cadre de l'entreprise, ensuite nous proposerons la modélisation UML de notre système, suivi de la présentation de l'architecture technique choisie et d'une explication pour chacune de nos décisions technologiques.

II.1 Analyse du système actuel

II.1.1 Problèmes identifiés sur le terrain

Avant toute création, nous avons pris le soin d'analyser et de saisir les défis auxquels les équipes sont confrontées tous les jours. Nous avons clairement identifié deux types de problème dans deux domaines qui sont distincts mais qui présentent une complémentarité.

D'un côté, la conformité RGPD concernant les chargés de traitement et le DPO se retrouvent confrontés à un nombre grandissant de requêtes et d'opérations à examiner. Chaque nouveau traitement de données doit être analysé en répondant aux questions suivantes : Quelle est la base légale pertinente ? Une analyse d'impact sur la protection des données (PIA) est-elle nécessaire ? Quels droits des personnes concernées doivent-êre garantis ? De ce fait, ces questions, bien que récurrentes, exigent systématiquement une recherche documentaire qui consomme un temps précieux. De plus, les réponses à ces questions ne sont pas toujours simples à trouver car elles sont liées au contexte spécifique du traitement, aux types de données concernées, aux destinataires visés ainsi qu'aux périodes de conservation prévues. Par conséquent, un outil capable de contextualiser automatiquement ces informations et de guider l'analyste dans son raisonnement constituerait un avantage significatif en termes de temps et de fiabilité.

D'un autre, le problème de la cybersécurité est d'une nature différente mais tout aussi pressant. En fait, les équipes opérationnelles produisent et obtiennent une quantité considérable de logs (des journaux d'événements produits par les équipements réseaux, les serveurs, les applications). Force est de constater qu'analyser ces logs manuellement pour y détecter des comportements anormaux s'avère être une tâche longue, monotone et susceptible d'être sujette à des erreurs humaines. Ainsi, les analystes risquent de passer à côté d'indicateurs de compromission. De surcroît, il est impératif que les équipes sur terrain puissent accéder rapidement à ces informations, même lorsqu'elles sont en mouvement. Un outil mobile permettant de soumettre des fichiers de logs et d'obtenir une analyse immédiate répondrait directement à ce besoin de réactivité.

II.1.2 Fonctionnalités du système existant

Avant l'arrivée de notre solution, l'entreprise disposait déjà de certains outils pour gérer la conformité et la cybersécurité, mais de manière partielle. Pour le RGPD, un logiciel web permettait aux chargés de traitement de renseigner les informations via un formulaire dédié. Cependant, toute question de conformité nécessitait encore de consulter manuellement les textes règlementaires ou de contacter directement le DPO, faute d'assistance automatisée. Concernant la cybersécurité, un reverse proxy filtrait et sécurisait les flux réseaux entrants. Mais l'analyse de logs et la détection des anomalies reposaient entièrement sur l'expertise des analystes, sans système automatisé pour prioriser les alertes ou détecter les incidents de façon intelligente. Suite à ces remarques observées, notre solution a apporté deux améliorations majeures : Un assistant IA capable de répondre aux questions liées au RGPD et à la conformité, réduisant la dépendance aux consultations manuelles. Une automatisation de l'analyse de logs, venant compléter le reverse proxy existant par une couche de détection intelligente

II.1.2.1 Architecture de sécurité - Zero Trust

Il faut préciser que la plateforme a été élaborée en suivant le principe du Zero Trust en matière de sécurité, c'est-à-dire qu'aucun élément n'est présumé digne de confiance par défaut, qu'il soit au sein ou hors du réseau. Ainsi, chaque accès est vérifié, approuvé et journalisé. Cette partie décrit les dispositifs de sécurité mis en place à chaque niveau du système.

a) Couche réseau - Nginx

Dans notre projet, nous avons mis en place Nginx en tant que reverse proxy sécurisé. Sa mission est de gérer la terminaison SSL/TLS (certificat Let's Encrypt ou auto-signé en interne), le filtrage des requêtes malformées, la limitation du débit (rate limiting) et le masquage de l'architecture interne (Annexe 1).

b) Couche authentification - Keycloak + JWT

Ici, c'est Keycloak qui est en charge de l'authentification via le protocole OAuth2/OpenID Connect. Une fois connecté, un jeton JWT signé par Keycloak est remis à l'utilisateur. Chaque requête vers le backend contient ce token dans l'en-tête Authorization (Annexe 2).

c) Gestion des rôles (RBAC)

Afin de garantir la confidentialité de données et le principe de moindre privilège, l'application repose sur un système de contrôle d'accès basé sur les rôles (RBAC). Le Tableau 6 présente la matrice des rôles et des permissions associées qui définit pour chaque profil utilisateur les droits d'accès aux différents modules du système.

TABLEAU 5 – Matrice des rôles et des permissions

Rôle	Module RGD	Module Cyber	Administration
Chargé de traitement (cdt)	Saisie, interrogation, export	Aucun accès	Aucun accès
DPO (dpo)	Tout + validation + dash-board	Aucun accès	Aucun accès
Analyste cybersécurité (analyste)	Aucun accès	Soumettre, consulter, alertes	Aucun accès
Administrateur (admin)	Accès complet	Accès complet	Gestion users + base connaissance

Source : Auteure, 2026

d) Protection contre les injections de prompts

Il est essentiel de comprendre que les injections de prompts posent un danger particulier pour les applications LLM. A titre d'exemple, un utilisateur malintentionné essaie de modifier sa demande afin d'éviter les directives de l'agent. Ainsi, notre dispositif de protection s'articule autour de trois niveaux complémentaires (Annexe 3).

e) Contraintes du système existant

Il est important de signaler que l'examen du système en place a mis en évidence quatre types de contraintes : Tout d'abord, les contraintes techniques telles que le manque de système d'automatisation dans le système. L'analyse des logs reposait entièrement sur les analystes malgré la présence d'un reverse proxy qui filtre les flux réseaux. Du côté RGD, le logiciel de saisie des traitements ne vérifie pas automatiquement la conformité et les informations saisies sont souvent incomplètes ou obsolètes faute d'assistance à la saisie. A part cela, il y a aussi les contraintes fonctionnelles. Par exemple, le traitement moyen d'une demande de conformité de RGD prenait environ des heures pour un chargé de traitement. L'analyse manuelle de fichier de logs de taille moyenne (quelques centaines d'événements) nécessitait entre 30 et 60 minutes d'expertise humaine, sans mécanisme de priorisation automatique pour guider le travail des

analystes. En outre, des contraintes organisationnelles ont aussi été remarquées. Par exemple, en l'absence du DPO ou d'un analyste senior, les réponses aux questions de conformité et les analyses de sécurité ne pouvaient pas être assurées avec la même fiabilité. Donc, il n'y a pas de capitalisation documentaire structurée. Enfin, le temps humain consacré à des tâches répétitives et à faible valeur ajoutée représente un coût important, alors qu'il pourrait être redirigé vers des activités d'analyse ou de conseil plus stratégique.

II.1.2.2 Solutions proposées

Pour palier ces problèmes, nous avons mis en place une solution qui complète l'infrastructure existante (notamment le reverse proxy) qui est le développement d'une plateforme d'agents IA spécialisés, déployée en environnement souverain (on-premise). Egalement, cette solution ajoute une analyse automatisée des logs grâce à l'IA et un assistant capable de répondre aux questions de conformité RGPD, contextualisé selon les spécificités de l'entreprise via le paradigme RAG. Ainsi, cette solution garantit la sécurité des données, offre la flexibilité nécessaire pour évoluer vers d'autres domaines métiers et permet de réduire les coûts marginaux liés à l'extension des fonctionnalités.

II.1.3 Cas d'usage retenus

A partir de cette analyse, il faut dire que deux cas d'usage principaux ont été retenus afin de structurer le développement de notre solution. En effet, ces cas d'usage permettent de répondre de manière ciblée aux besoins identifiés en amont.

Tout d'abord, le premier cas d'usage concerne l'agent RGPD accessible via l'interface web. Plus précisément, un chargé de traitement ou un DPO saisit les caractéristiques d'un traitement de données, les finalités, catégories de données, base légale envisagée, destinataires, durée de conservation afin de solliciter une analyse contextualisée et automatisée. A cet égard, l'utilisateur peut interroger l'agent pour déterminer si le traitement envisagé est conforme à la réglementation en vigueur, si une DPIA est requise, ou encore quelles mentions doivent être prévues. Ainsi, l'outil ne se limite pas à une réponse binaire, mais fournit un accompagnement argumenté. En outre, l'agent s'appuie à la fois sur la base documentaire interne de l'organisation et sur les textes réglementaires de référence. Par conséquent, les réponses générées sont contextualisées et alignées avec le cadre juridique applicable. De ce fait, l'agent constitue un véritable outil d'aide à la décision pour les acteurs en charge de conformité.

Ensuite, le second cas d'usage concerne l'agent cybersécurité accessible depuis l'application mobile. Dans ce cadre, un analyste soumet un fichier de logs directement dans l'application afin de procéder à une analyse automatisée des événements enregistrés. A partir de ces données, l'agent examine le contenu, identifie les événements suspects et les classes selon leur niveau de criticité. Ainsi, les incidents sont hiérarchisés de manière structurée, facilitant leur traitement prioritaire. Par ailleurs, l'agent génère un rapport détaillé synthétisant les anomalies détectées ainsi que les recommandations associées.

En cas de détection d'une anomalie critique, une notification apparaît immédiatement sur l'écran de l'utilisateur. Par conséquent, ce dispositif renforce la capacité de surveillance continue et améliore la réactivité opérationnelle face aux menaces potentielles.

II.1.3.1 Acteurs du système

Notre plateforme est en interaction avec quatre catégories d'acteurs : le chargé de traitement est l'utilisateur principal du module RGPD : il saisit les informations relatives aux traitements et interagit avec l'agent pour obtenir des analyses. Ensuite, le DPO supervise tous les traitements, valide les analyses réalisées par l'agent et a la possibilité de consulter des tableaux de bord relatifs à la conformité. A part ça, il y a l'analyste en cybersécurité qui utilise l'application pour soumettre des logs et consulter les résultats d'analyse. Enfin, l'administrateur gère les comptes utilisateurs, les droits d'accès et la mise à jour de base de la connaissance.

II.2 Expression des besoins

II.2.1 Description du futur système

Le futur système se présente comme une plateforme multi-agents composé de deux modules complémentaires : un module web et un module mobile. Il est à noter que chaque module intègre un agent d'intelligence artificielle spécialisé dans un domaine métier précis, capable soit de répondre à des questions contextualisées, soit d'analyser des données structurées.

En outre, le système s'adresse à l'ensemble des utilisateurs internes concernés par les problématiques de RGPD et de la cybersécurité : chargés de traitement, DPO, analystes cybersécurité et administrateurs. A noter qu'il ne remplace pas l'expertise humaine mais est considéré en tant qu'appui pour faciliter, accélérer et sécuriser le travail quotidien de ces professionnels.

II.2.2 Fonctionnalités clés

A priori, le module web permet de :

- la saisie et la gestion des traitements de données,
- l'interaction avec un agent RGPD sous forme de conversation pour obtenir des réponses contextualisées,
- la génération de fiches de traitement au format PDF,
- un tableau de bord de suivi de la conformité pour le DPO,

Quant à la module mobile, cette dernière permet :

- l'envoi de fichiers de logs directement depuis le terminal,
- l'envoi de fichiers de logs directement depuis le terminal,
- l'analyse automatique des logs avec classification des événements par niveau de criticité (normal, suspect, critique),
- un affichage hiérarchisé des résultats pour identifier rapidement les incidents importants,
- l'envoi de notifications en cas d'événement critique, la consultation de l'historique des analyses.

II.2.3 Intégration avec le système existant

Il faut souligner que la mise en place de notre solution dans l'infrastructure existante ne modifie pas les outils existants. D'un côté, le module RGPD peut importer des documents dans les formats courants (PDF, WORD, texte), ce qui permet de réutiliser directement les politiques et procédures déjà existantes. D'un autre côté, le module cybersécurité accepte les formats de logs standards (.log, .txt, CSV), compatibles avec la majorité des outils SIEM et des équipements réseau. Par ailleurs, l'authentification est générée via Keycloak. Le backend expose une API REST qui permettra à l'avenir d'intégrer la plateforme avec d'autres outils internes grâce à des webhooks ou des connecteurs spécifiques.

II.2.4 Etude de faisabilité

II.2.4.1 Faisabilité technique

Sur le plan technique, le projet est tout à fait réalisable. Les technologies utilisées ont été choisis minutieusement avec une communauté active, ce qui garantit leur stabilité et leur pérennité. Par exemple, le modèle de langage Mistral 7B qui est exécuté via Ollama localement a été testé sur l'infrastructure disponible et les résultats obtenus sont conformes aux attentes.

II.2.4.2 Faisabilité économique

Notons que le projet repose entièrement sur des technologies open source afin d'éviter les coûts de licence souvent élevés pour ce type de solution. Par ailleurs, notre principal investissement était au niveau du temps de développement et de rédaction, environ huit semaines de travail. Ainsi, une fois que la solution soit déployée, les coûts d'exploitation restent limités puisqu'ils concernent l'hébergement sur les serveurs internes de l'entreprise (on-premise)

II.2.4.3 Faisabilité organisationnelle

En tenant compte des besoins des utilisateurs finaux, ils ont participé massivement dans la conception de la solution en montrant de l'intérêt pour l'outil notamment pour le gain de temps. Malgré cela, la résistance au changement constitue souvent un risque dans les projets de transformation numérique.

II.2.4.4 Faisabilité temporelle

Le planning prévu pour huit semaines a bien été respecté. Cependant, certaines fonctionnalités secondaires ont été reportées à des versions futures sans impacter les fonctionnalités essentielles du système.

II.2.5 Spécification technique des besoins

Les exigences non fonctionnelles transversales ont été formalisées selon cinq axes (Tableau 6).

TABLEAU 6 – Exigences non fonctionnelles du système

Axe	Exigence	Indicateur cible
Performance	Temps de réponse agent RGPD	< 10 secondes
Performance	Temps d'analyse d'un fichier logs (500 lignes)	< 30 secondes
Disponibilité	Taux de disponibilité de la plateforme	> 99% en heures ouvrées
Sécurité	Chiffrement de toutes les communications	HTTPS / TLS 1.3
Sécurité	Authentification forte	OAuth2 + JWT via Keycloak
Sécurité	Isolation des données entre rôles	RBAC granulaire
Ergonomie	Prise en main sans formation	Interface intuitive, aide contextuelle
Portabilité	Compatibilité mobile	iOS et Android (React Native)
Maintenabilité	Ajout d'un nouvel agent métier	Sans refonte de l'architecture
Conformité	Hébergement des données	100% on-premise, aucun transfert externe

Source : Auteure, 2026

II.2.5.1 Spécifications fonctionnelles

Les spécifications fonctionnelles détaillent les capacités que le système doit posséder selon la perspective de l'utilisateur. A ce titre, elles ont été établies sur la base des cas d'utilisation identifiés et servent de référence pour l'organisation de la conception ainsi que des phrases de test. En d'autres termes, elles traduisent les besoins métiers en exigence opérationnelles concrètes.

S'agissant du modèle web, le système doit offrir à un utilisateur authentifié la possibilité d'entrer les informations relatives à un traitement de données. Plus précisément, il doit pouvoir interagir avec l'agent RGPD au moyen d'une interface de discussion contextuelle, consulter l'historique de ses communications et créer ou exporter une fiche de traitement. Ainsi, l'utilisateur bénéficie d'un environnement centralisé facilitant le suivi et la formation des analyses effectuées.

Par ailleurs, il est indispensable que l'administrateur dispose de fonctionnalités dédiées à la gestion des utilisateurs. A cet effet, il doit pouvoir définir leurs droits d'accès et actualiser la base de connaissance de l'agent. De cette manière, le système garantit à la fois la sécurité des accès et la pertinence continue des réponses fournies par l'agent. Concernant

le module mobile, le système doit autoriser un analyste à se connecter en toute sécurité, soumettre un fichier de logs, examiner les résultats de l'analyse avec les niveaux de criticité appropriés, et recevoir des notifications push lors d'une détection critique.

Par ailleurs, l'interface doit être conçue pour être rapide, lisible et ergonomique. En effet, son utilisation en conditions de terrain exige une navigation fluide et une présentation claire des informations. De ce fait, l'expérience utilisateur constitue un enjeu central pour assurer l'efficacité opérationnelle du module mobile.

II.2.5.2 Spécifications non-fonctionnelles


Outre les fonctionnalités précédemment décrites, divers critères transversaux ont orienté nos décisions de conception. En effet, ces exigences non fonctionnelles conditionnent la robustesse et la pérennité du système. Concernant la sécurité, toutes les transmissions doivent se faire à travers HTTPS, l'accès au système est sécurisé par une authentification renforcée et aucune donnée sensible ne doit transiter vers des infrastructures étrangères. En matière de performance, l'agent RGPD doit être capable de fournir des réponses en moins de dix secondes et d'analyser un fichier de logs standard en moins de trente secondes.

En termes de maintenabilité, l'architecture doit faciliter l'intégration de nouveaux agents métiers sans nécessiter une refonte complète du système. Enfin pour ce qui est de la conformité réglementaire, il est impératif que l'ensemble du système adhère aux stipulations du RGPD. A cet égard, une attention particulière est accordée aux principes de minimisation des données et de traçabilité des accès. Par conséquent, chaque action effectuée au sein du système doit pouvoir être enregistrée et auditée.

II.3 Conception du système futur

II.3.1 Diagramme de cas d'utilisation

Le diagramme de cas d'utilisation illustre les interactions entre les utilisateurs du système et les fonctionnalités à leur disposition (Figure 4). Il offre un aperçu général de ce que fait le système, sans se plonger dans les spécificités techniques de sa manière d'agir.




Source : Auteure, 2026

FIGURE 4 – Diagramme de cas d'utilisation

Dans notre schéma, quatre acteurs majeurs sont identifiés : le Chargé de traitement, le DPO, l'Analyste cybersécurité et l'administrateur. Tout d'abord, le Chargé de traitement peut saisir un traitement, interroger l'agent RGPD, accéder à son historique d'échanges et exporter un fichier traitement. Quant au DPO, il bénéficie de toutes les fonctionnalités précédentes sauf l'exportation de fichiers traitements, ainsi que l'accès au tableau de bord de conformité et à la validation des analyses. Ensuite, l'Analyste en cybersécurité peut soumettre des logs, consulter les résultats d'analyse et recevoir des alertes push. Enfin, l'administrateur est chargé de la gestion des comptes, les droits d'accès et la base des connaissances.

II.3.2 Diagramme de séquence - Agent RGPD

Le diagramme de séquence démontre le déroulement temporel d'une interaction type : un chargé de traitement pose une question à l'agent et le système produit une réponse contextualisée. Il importe de souligner que ce diagramme met en évidence les échanges entre les différentes couches de l'architecture et montre comment le pipeline RAG s'intègre dans le flux (Figure 5).



Source : Auteure, 2026


FIGURE 5 – Diagramme de séquence Agent RGD

L'interaction commence quand l'utilisateur pose sa question via l'interface en ligne. Ensuite, la requête est transmise au backend FastAPI via le Reverse proxy Nginx. Puis le service RAG prend le relais : il transforme la question en vecteur, interroge la base vectorielle ChromaDB pour retrouver les morceaux de documents les plus appropriés, puis transmet la question enrichie de ce contexte au modèle de langage local. Après cela, la réponse générée est renvoyée à l'interface et présentée à l'utilisateur, qui est accompagnée des sources consultées.

II.3.3 Diagramme de séquence - Agent cybersécurité

Ce diagramme illustre le déroulement du processus, allant de la transmission d'un fichier de journaux par l'analyste à la présentation des résultats sur son appareil mobile (Figure 6). La logique ici diffère de celle du module RGD : il ne s'agit pas d'une interaction conversationnelle mais d'un pipeline d'analyse automatique.

Plus précisément, l'analyste transmet son dossier via l'application mobile. Le fichier est transmis au backend via le reverse proxy qui vérifie l'authentification. Ensuite, le service d'analyse prend en charge le fichier : il le décompose, extrait les événements et les soumet au modèle de classification. Un niveau de criticité est attribué à chaque événement.



Source : Auteure, 2026

FIGURE 6 – Diagramme de séquence Agent Cybersécurité

Ainsi, les résultats sont compilés renvoyés à l’application. En cas de détection d’un événement critique, une alerte push est automatiquement activée.

II.3.4 Diagramme de classes

Ce diagramme représente la structure statique de notre système à savoir les entités majeurs qui le constituent, leurs attributs et les relations qui les unissent. Cette modélisation constitue le socle du modèle logique de données et de l’architecture logicielle des deux applications.

Tout d’abord, le système est structuré autour d’une hiérarchie d’Utilisateurs basée sur l’héritage. Il est essentiel de noter que la classe abstraite Utilisateur centralise les données d’identification commune telles que le nom, email et authentification. Elle se spécialise en 4 rôles distincts qui sont répartis dans deux domaines fonctionnels :

- Le module Gestion RGPD : il implique le Chargé de traitement qui se charge de la saisie et de la gestion des fichiers traitements. Quant au DPO, il audite et valide la conformité du traitement (Figure 7).
- Le module Cyber-Surveillance : il implique l’Analyste Cyber qui pilote les investigations et l’Administrateur qui est garant de la base de connaissances et de la gestion des comptes (Figure 8).

Dans le module RGPD (Figure 10), la gestion des traitements de données a été améliorée afin de mieux répondre aux besoins réels des entreprises en matière de conformité. En plus des informations de base comme la finalité de traitement, la base légale ou les destinataires des données, le système prend désormais en compte les transferts de données en dehors de l’Union Européenne. En outre, chaque traitement intègre une analyse de conformité qui est stockée avec son statut (EnCours, Conforme ou NonConforme), ce qui permet de suivre son niveau de conformité au regard des exigences réglementaires.

Notons que cette analyse repose sur les documents enregistrés dans la base de connaissance. En effet, chaque traitement peut être justifié par plusieurs documents sources qui sont utilisés pour appuyer l’évaluation réalisée. Ici, le DPO intervient dans ce processus en auditant les traitements et en validant leur conformité.

Enfin, le module conversationnel assure la traçabilité des échanges avec l’intelligence artificielle. Les conversations sont enregistrées de manière structurée et chaque réponse générée par l’agent peut être reliée aux documents mobilisés comme les sources. Par conséquent, cela améliore la cohérence, la transparence et la vérifiabilité des réponses fournies.




FIGURE 7 – Diagramme de classe – Modules Conversationnel et RGPD




FIGURE 8 – Diagramme de classe – Application Cyber-Surveillance

Quant au module de cybersécurité (Figure 11), il permet d’analyser des fichiers de logs afin d’identifier d’éventuelles

anomalies ou menaces. Lorsqu'un utilisateur soumet un fichier, le système traite les événements contenus dans ce dernier, les classe selon leur niveau de gravité (normal, suspect et critique), puis génère un rapport d'analyse.

En outre, les informations principales de cette analyse sont persistées dans la table `analysis_reports`. Notons que cette table contient notamment l'identifiant de l'utilisateur concerné, le nom du fichier analysé, le nombre total d'événements détectés, le nombre d'événements normaux, suspects et critiques ainsi que le rapport complet au format JSON. Il faut souligner qu'elle est liée à la table `users`, car chaque rapport appartient à un utilisateur précis. Ainsi, un utilisateur peut disposer de plusieurs rapports d'analyse tandis qu'un rapport est associé à un seul utilisateur.

Lorsque le rapport contient des événements critiques, le système crée une entrée dans la table `notifications`. Cette dernière est associée à l'utilisateur concerné grâce à `user_id` et peut aussi être liée au rapport correspondant grâce à `related_report_id`. En outre, cela permet d'avertir l'analyste qu'une menace importante a été détectée et de conserver une historique des alertes générées.


Quant à la table `users`, elle joue un rôle central dans le système. Elle contient les informations d'authentification de l'utilisateur, comme l'email, le mot de passe hashé, le rôle (ici c'est analyste par défaut). Elle est reliée aux rapports d'analyse, aux notifications et aux tokens de réinitialisation du mot de passe.

A part cela, nous avons aussi la table `password_reset_token` qui gère le mot de passe oublié. A priori, quand un utilisateur demande une réinitialisation, un token temporaire est généré et enregistré dans cette table avec sa date d'expiration. Ce token est relié à l'utilisateur concerné. Egalement, lorsqu'il est utilisé avec succès, sa date d'utilisation est enregistrée, d'où sa réutilisation.

Enfin, le tableau de bord ne constitue pas une table indépendante. Il est construit à partir des données déjà stockées, principalement celles de la table `analysis_reports`. Il permet d'afficher une synthèse globale, à l'exemple du nombre d'analyses effectuées, le nombre total d'événements, les événements critiques et les derniers rapports. Ainsi, le tableau de bord agit comme une vue statistique calculée à partir des rapports existants afin d'offrir à l'analyste une vision claire de l'état de sécurité du système.

II.3.5 Diagramme d'activité - Traitement d'une demande RGPD

Ce diagramme modélise le flux complet de traitement d'une demande RGPD, depuis la saisie des informations par l'utilisateur jusqu'à la production d'une fiche de traitement validée (Figure 9).




Source : Auteure, 2026

FIGURE 9 – Diagramme d'activité

Egalement, il offre la possibilité de voir les choix effectués à chaque phase ainsi que les itinéraires alternatifs selon les situations rencontrées.

II.3.6 Diagramme de déploiement

Ce diagramme représente l'infrastructure physique et logique sur laquelle repose notre solution. Il montre comment les différents composants sont répartis et comment ils communiquent entre eux. Il est essentiel de rappeler que notre architecture repose sur un serveur on-premise, c'est-à-dire, au sein de l'infrastructure de l'entreprise afin que les informations sensibles restent toujours à l'intérieur des limites de l'entreprise (Figure 10).



Source : Auteure, 2026

FIGURE 10 – Diagramme de déploiement

Ce serveur héberge l'ensemble des composants : le reverse proxy Nginx, le backend FastAPI, le modèle de langage via Ollama, la base vectorielle ChromaDB et la base de données relationnelles PostgreSQL. Ainsi, les utilisateurs se connectent à la plateforme soit par le biais d'un navigateur web, soit via l'application mobile Flutter, dans les jeux de scénario avec une connexion HTTPS sécurisée.

III REALISATION

Les deux premières parties ont établi les bases théoriques et la conception de notre solution. Cette troisième partie marque la transition vers la réalité concrète : la création réelle de la plateforme, les caractéristiques mises en œuvre, et les résultats obtenus lors des phases de test. Nous présentons ici le résultat de plusieurs semaines de travail, en respectant une séquence logique : début avec le module web intégrant l'agent RGPD, suivi par l'application mobile axée sur la cybersécurité, et finalement un bilan sincère de ce qui a été accompli, de ce qui est efficace, ainsi que des axes d'amélioration que nous identifions pour l'avenir.

III.1 Choix et présentation des outils

III.1.1 Stack technologique

A priori, chaque technologie sélectionnée dans notre stack a été soumise à une évaluation rigoureuse. Le Tableau 7 présente nos choix et les alternatives que nous avons écartées avec les raisons de nos décisions.

TABLEAU 7: Justification des choix des outils

Composant	Technologie choisie	Alternative écartée	Raison du choix
LLM local	Ollama + Mistral 7B	OpenAI API (GPT-4)	Données sensibles : hébergement local obligatoire. Pas de dépendance externe.
Agent RAG	LangChain	LlamaIndex	Écosystème mature, documentation riche, intégration native avec Ollama et ChromaDB.
Base vectorielle	ChromaDB	Pinecone	Open source, déploiement local, pas de coût d'abonnement, simplicité d'intégration.
Backend API	FastAPI (Python)	Django, Flask	Performances élevées, typage fort avec Pydantic, natif async, idéal pour les pipelines IA.
Frontend Web	React.js + Tailwind	Vue.js, Angular	Communauté très large, composants riches, cohérence avec React Native pour le mobile.
Application Mobile	Flutter	React Native	Performance native, rendu fluide, UI homogène, compilation directe, widgets personnalisables,, moins de dépendance aux bridges, meilleure cohérence cross-platform, rapidité d'exécution.
Base de données	PostgreSQL + pgvector	MongoDB	Fiabilité, conformité ACID, support natif des vecteurs via l'extension pgvector.
Authentification	Keycloak	Auth0, Firebase Auth	Open source, déploiement on-premise, gestion fine des rôles, compatible RGPD.
Reverse Proxy	Nginx	Apache, Caddy	Performance éprouvée, configuration flexible, termination SSL, load balancing.
Classification logs	Scikit-learn / BERT	Règles statiques	Détection de patterns complexes, meilleure précision que les règles manuelles.

Source : Auteure, 2026

III.1.2 Choix et justification du modèle de classification des logs

Pourquoi un modèle déterministe et non génératif ? Nous avons choisi un modèle de classification supervisé pour le module de détection des anomalies dans les journaux car il répond à des critères opérationnels spécifiques. Contrairement au LLM génératif qui génère une réponse textuelle variable en fonction du contexte, un modèle de classification fournit une sortie distincte et reproductible comme normal, suspect ou critique pour un même événement d'entrée.

En outre, dans le domaine de la cybersécurité, cette caractéristique de déterminisme est primordiale : deux experts qui présentent le même fichier de journaux devraient obtenir des résultats identiques.

Par ailleurs, les LLMs génératifs introduisent une latence qui ne correspond pas à l'exigence de traitement en moins de trente secondes stipulée dans les spécifications fonctionnelles. D'où notre choix par rapport à ce modèle de classification léger qui peut gérer des milliers d'événements par seconde sur un serveur ordinaire, contrairement à un LLM qui prendrait plusieurs minutes à le faire.

III.1.2.1 Modèle retenu : Random Forest avec features engineered

Suite à une analyse comparative des différentes méthodes disponibles, le modèle Random Forest [2] est choisi comme stratégie principale, accompagné d'un processus d'extraction de caractéristiques ajusté aux logs variés. Plusieurs raisons sous-tendent ce choix.

Tout d'abord, le Random Forest obtient des scores F1 supérieurs à 0.97 sur l'ensemble de données HDFS dans les études de référence, dépassant les SVM et les réseaux de neurones simples sur des ensembles de données d'une taille moyenne du fait de sa performance.

Ensuite, elle possède la capacité de déterminer l'importance des caractéristiques qui permet de repérer les éléments des logs qui contribuent le plus à la classification, facilitant ainsi l'audit et renforçant la confiance des analystes. N'oublions pas sa robustesse face aux valeurs anormales et n'exige pas une normalisation stricte des données, ce qui constitue un atout face à des journaux variés.

Enfin, après son entraînement, le modèle peut être sérialisé (avec pickle/joblib) et chargé en mémoire pour effectuer des inférences en temps réel sans nécessiter de GPU.

III.1.2.2 Structure du pipeline de classification

Le processus de classification suit quatre étapes progressives appliquées à chaque événement dérivé du fichier de logs présenté à savoir :

a) Etape 1 : Parsing

Ici, le fichier de logs est analysé par un parser configurable capable de traiter les formats syslog, CEF (Common Event Format), JSON structuré, et texte brut. Chaque ligne est décomposée en champs structurés : timestamp, source, niveau de sévérité déclaré, message, IP source/destination le cas échéant.

b) Etape 2 : Feature extraction

A partir des données structurées, un vecteur de caractéristiques numériques est élaboré pour chaque événement. Parmi les critères sélectionnés, on trouve : le moment de l'événement (heure précise, jour de la semaine), la fréquence de l'événement d'origine sur les 60 dernières secondes, le degré de gravité codé numériquement, l'occurrence de mots clés liés à la sécurité (échoué, non autorisé, refusé, exploitation, injection, etc.), ainsi que la nouveauté de l'IP source par rapport à une référence établie.

c) Etape 3 : Classification

Maintenant, le vecteur de caractéristiques est passé au modèle Random Forest, qui produit une étiquette de classe (normal / suspect / critique) et un score de confiance (probabilité liée à la classe prédite).

d) Etape 4 : Post-processing

Enfin, les événements classés sont regroupés en fonction de leur source, de la fenêtre temporelle et du niveau de gravité. Un événement isolé identifié comme suspect peut être requalifié en tant que critique si plusieurs incidents suspects successifs proviennent de la même origine dans une période restreinte (corrélation temporelle).

e) Labels de sortie et seuils de décision

Le Tableau 8 illustre les différents degrés de classification des événements en fonction de leur risque et suggère les mesures appropriées pour chaque degré.

TABLEAU 8 – Tableau récapitulatif des labels et actions de surveillance

Label	Critères de classification	Action recommandée
NORMAL	Comportement conforme aux patterns habituels, score de confiance > 0.85	Aucune action requise
SUSPECT	Déviations partielles, score ambigu entre 0.60 et 0.85, ou pattern inhabituel isolé	Surveillance renforcée, log pour investigation
CRITIQUE	Signature d'attaque connue, anomalie forte (score > 0.85 classe critique), ou corrélation temporelle de suspects	Alerte push immédiate, escalade SOC

Source : Auteure, 2026

III.2 Structure générale de l'application

III.2.1 Architecture du module Web - Agent RGPD

Le module web est développé en s'appuyant sur un pipeline RAG intégral. Au cours de l'étape d'initialisation, les documents de référence de l'organisation politiques internes, textes réglementaires, guides pratiques sont chargés et divisés en segments de taille appropriée (Figure 11). Ils sont ensuite convertis en vecteurs grâce à un modèle d'embedding et sauvegardés dans ChromaDB. Cette action est effectuée une seule fois, puis actualisée chaque fois qu'un nouveau document est ajouté à la base de données (Figure 12).

Au cours d'une interaction avec l'utilisateur, la procédure est la suivante : la question posée par l'utilisateur est également convertie en vecteur. ChromaDB réalise une recherche de similarité afin de déterminer les extraits documentaires qui sont le plus sémantiquement apparentés à la question. Ces morceaux sont réunis dans un contexte, qui est ensuite fourni au modèle de langage Ollama avec la question initiale (Figure 12). Ainsi, la Figure 13 démontre que ce choix d'architecture assure deux caractéristiques fondamentales : la traçabilité (chaque réponse peut être validée en confrontant avec les sources) et la protection de la confidentialité (aucune information ne sort de la structure interne).




FIGURE 11 – Schéma de l'architecture Web pour l'agent RGPD : Phase d'initialisation




FIGURE 12 – Schéma de l'architecture Web pour l'agent RGD : Phase d'interaction utilisateur





FIGURE 13 – Schéma de l'architecture Web pour l'agent RGD : Les propriétés garanties

III.2.1.1 Présentation de l'interface Web


Dans la page d'authentification (Figure 14), l'accès à la plateforme se fait via une connexion sécurisée par KeyCloak. Quand l'utilisateur a soumis ses identifiants, le frontend échange un code d'autorisation contre un token JWT, qui est ensuite inclus dans toutes les requêtes vers backend. Cependant, l'utilisateur est tout de suite redirigé vers la page de connexion si son token est expiré.



Source : Auteure, 2026

FIGURE 14 – Page de connexion


Quant à la page Dashboard (Figure 15), elle montre les deux principales fonctionnalités de ce logiciel qui sont la conversation avec l'agent RGD et l'analyse de conformité des traitements. (Suite)



Source : Auteure, 2026


FIGURE 15 – Page Dashboard du rgpd_web

Ensuite, la page Traitement (Figure 16) affiche le formulaire d'ajout de traitement en remplissant les champs suivants : finalité, base légale, catégories de données traitées, destinataires, transferts éventuels vers UE et durée de conservation. Une fois le formulaire complété, l'utilisateur peut voir à côté la conformité du traitement qu'il a saisi comme dans l'exemple ci-dessus.



Source : Auteure, 2026

FIGURE 17 – Page d'interaction avec l'agent RGPD




Source : Auteure, 2026

FIGURE 18 – Historique des conversations avec l’agent RGD

III.2.2 Architecture du module mobile - Agent cybersécurité

L’architecture du module mobile est différente et conçue pour répondre aux exigences de l’analyse des journaux. L’application Flutter interagit avec le serveur via une API REST sécurisée. Quand un analyste remet un fichier de logs, ce dernier est acheminé vers le service d’analyse du backend (Figure 19).

Ce service analyse le fichier afin d’isoler les événements individuels, ensuite il présente chaque événement au modèle de classification. Ce modèle, formé sur des ensembles de données de logs étiquetés, attribue à chaque événement un indice de gravité et une classification : normal, suspect ou critique. Les événements sont par la suite regroupés pour générer un rapport récapitulatif, qui est renvoyé à l’application mobile et présenté de manière explicite et structurée.



Source : auteure


Source : Auteure, 2026

FIGURE 19 – Architecture mobile de l’agent cybersécurité

III.2.2.1 Présentation de l'interface mobile


Dans la page de connexion (Figure 20), elle suit les mêmes logiques que celles de l'agent RGPD. L'utilisateur saisit ses identifiants Keycloak et qui sont vérifiés via le flux OAuth2 Resource Owner Password. En cas d'échec, un message d'erreur s'affiche et il faut recommencer la saisie.

Ensuite, dans le cas où l'utilisateur oublie son mot de passe, il demande un lien de réinitialisation par email qui expire après 15 minutes (Figure 21). En effet, cela lui permet de créer un nouveau mot de passe sécurisé tout en maintenant la traçabilité de l'action dans les logs de sécurité,



Source : Auteure, 2026


FIGURE 20 – Page de connexion de l'appli mobile Cybersécurité



Source : Auteure, 2026

FIGURE 21 – Réinitialisation mot de passe


Ensuite, la page de Dashboard illustre de multiples données à savoir l'historique des analyses soumises par l'utilisateur qui contient le nom du fichier, la date d'analyse, le nombre d'événements détectés et un indicateur visuel du niveau de criticité global (vert, orange, rouge). Aussi, un filtre permet d'afficher uniquement les analyses contenant des événements critiques ou suspects. Il est possible de naviguer vers la page de détail de l'analyse du log en cliquant sur la flèche tout à droite (Figure 22).



Source : Auteure, 2026

FIGURE 22 – Dashboard Appli mobile agent_{cybersec}


Quant à la page de soumission de fichiers logs (Figure 23), l'utilisateur peut uploader un fichier via son ordinateur. Notons que les formats supportés sont les fichiers textes bruts comme .log, .txt et les fichiers CSV. Ensuite, après la sélection du fichier, un résumé de ce dernier apparaît en bas avant de cliquer sur le bouton d'analyse du fichier.



Source : Auteure, 2026

FIGURE 23 – Soumission de fichier log

Après la soumission du fichier log, il faut souligner que quand le système détecte des anomalies critiques, il informe l'utilisateur sous forme de popup avec un badge rouge (Figure 24). Puis, voici le résultat des analyses de ce dernier. Ici, nous avons soumis un exemple de log quelconque et nous pouvons voir les résultats à travers le résumé et en bas s'affiche les événements détectés. Il est possible d'exporter les résultats et de soumettre un autre fichier (Figure 25).



Source : Auteure, 2026

FIGURE 24 – Popup alerte de détection d'incidents critiques



Source : Auteure, 2026

FIGURE 25 – Résultat des analyses d'un fichier log

Maintenant, après l'affichage des résultats des logs, la génération PDF permet d'exporter les événements suspects dans un rapport structuré et partageable qui offre une vue d'ensemble pour l'analyse approfondie ou la documentation (Figure 26, 27, 28, 29). Ici, la fonctionnalité PDF transforme les alertes détectées en un document professionnel avec statistiques et détails chronologiques. Par conséquent, cela facilite le partage avec les équipes de sécurité ou l'archivage des incidents.



RAPPORT D'ANALYSE DE LOGS

CyberSOC Analyzer

15/05/2026 12:02

Fichier analysé:	critical_example.txt
Analysé par:	priscilliachryso@gmail.com
ID utilisateur:	2
Date d'analyse:	15/05/2026 12:02:29

SYNTHÈSE DE L'ANALYSE



DISTRIBUTION DES ÉVÉNEMENTS



Source : Auteure, 2026

FIGURE 26 – En-tête du rapport PDF

ÉVÉNEMENTS CRITIQUES

10 événement(s) critique(s) détecté(s)


1	2026-05-15 02:44:18.774 [CRITICAL] app=myapp env=production host=srv-01 DATABASE CONNECTION POOL EXHAUSTED. Active connections: 20/20. Requests queued: 143. Possible deadlock or connection leak.	1%
2	2026-05-15 02:44:45.118 [CRITICAL] app=myapp env=production host=srv-01 UNHANDLED EXCEPTION ☒ Service crashed. Restarting worker process #4.	1%

Source : Auteure, 2026

FIGURE 27 – Affichage des événements critiques

ÉVÉNEMENTS SUSPECTS

12 événement(s) suspect(s) détecté(s)



Source : Auteure, 2026

FIGURE 28 – Affichage des événements suspects

CONCLUSION ET RECOMMANDATIONS

CONCLUSION

L'analyse révèle une situation critique avec de multiples incidents de sécurité. Une action immédiate est requise pour sécuriser le système.

RECOMMANDATIONS

- ☑ Investiguer immédiatement les événements critiques
- ☑ Vérifier l'intégrité des systèmes affectés
- ☑ Mettre en place des mesures de containment
- ☑ Surveiller les activités suspectes identifiées
- ☑ Renforcer les contrôles de sécurité
- ☑ Examiner les logs historiques pour des patterns similaires

PROCHAINES ÉTAPES

- 1 Analyser les événements critiques en priorité
- 2 Documenter les incidents dans le système de ticketing
- 3 Mettre à jour les règles de détection si nécessaire
- 4 Planifier une revue de sécurité avec l'équipe

Source : Auteure, 2026

FIGURE 29 – Recommandations dans PDF

III.2.3 Sécurisation de l'architecture

Il est capital de noter que la sécurité ne représente pas une couche additionnelle appliquée au système, mais elle est incorporée dès la phase de conception et à chaque stade de l'architecture. Cette méthode, couramment appelée Security By Design constitue une condition essentielle dans un environnement où les données gérées sont délicates et les défis réglementaires considérables.

Au niveau du réseau, Nginx gère la terminaison SSL et l'inspection des requêtes. Toutes les transmissions de données se font en HTTPS, y compris celles qui ont lieu en interne entre les éléments du backend. Les ports non nécessaires sont fermés et seuls les services exposés à l'extérieur sont accessibles depuis l'interface publique.

Sur le plan applicatif, Keycloak assure l'authentification et les permissions en suivant le modèle Zero Trust. Chaque jeton d'accès doit être renouvelé régulièrement et les rôles sont bien séparés : un responsable de traitement ne peut accéder aux fonctionnalités réservées au DPO, et un analyste en cybersécurité n'a aucune visibilité sur les traitements RGPD d'un autre département.

Du côté des données, PostgreSQL assure à la fois leur intégrité et leur traçabilité : chaque accès, chaque modification laisse une trace dans les logs d'audit.

ChromaDB ne conserve que des vecteurs et des métadonnées, les documents d'origine demeurant dans un espace de stockage distinct à accès limité.

III.3 Description technique du logiciel

Il est important de noter que cette section met en exergue la description technique des deux plateformes développées concernant son architecture interne, ses composants logiciels, les flux de données qui les relient, les interfaces programmables exposées ainsi que les mécanismes de sécurité mises en oeuvre. Aussi, elle constitue le référentiel technique de la solution et complète la modélisation UML présentée dans les sections précédentes.

III.3.1 Architecture globale du système

A priori, la plateforme est élaborée sur la base d'une architecture à couches distinctes, où chaque couche possède une fonction particulière et ne communique qu'avec les couches voisines. Cette méthode, appelée architecture N-tiers, assure la capacité de maintenance, de test et d'évolution du système (Figure 33).

Il faut savoir que Nginx, agissant en tant que point d'entrée unique du système, est le seul intermédiaire par lequel toutes les communications entre la couche présentation et la couche applicative doivent passer. Par conséquent, il n'y a aucun service interne qui est directement accessible depuis l'extérieur. Ainsi, cette mise en place diminue largement la surface vulnérable et adhère au principe du Zero Trust.

Un autre point à souligner est le fait que chaque service n'est accessible qu'au travers d'une interface contrôlée. A titre d'exemple : les bases de données, le modèle LLM et ChromaDB ne sont jamais exposés directement car ils ne communiquent qu'avec le backend FastAPI via le réseau Docker interne.


III.3.2 Pipeline RAG - Agent RGPD

Il est essentiel de comprendre que le mécanisme principal du module RGPD est le pipeline RAG (Retrieval-Augmented Generation). Cela autorise l'agent à fournir des réponses basées sur le corpus documentaire de l'organisation, plutôt que de composer du texte uniquement à partir de ses paramètres d'apprentissage. Ainsi, ce pipeline comprend deux étapes distinctes à savoir : l'étape d'ingestion (hors ligne) et l'étape de questionnement (en temps réel).

III.3.2.1 Phase 1 - Ingestion des documents

La Figure 30 illustre le visuel de l'architecture globale du système. Pour commencer, l'ingestion est la phase préparatoire qui consiste à transformer les documents de référence en une base de connaissance interrogeable et elle se

déroule en quatre étapes successives.



Source : Auteur, 2026

FIGURE 30 – Architecture globale du système

a) Etape 1 - Chargement des documents

Rappelons que les documents sources comme les politiques de confidentialité, les guides CNIL, les notes internes et les textes réglementaires sont chargés depuis un répertoire dédié sur le serveur. Ensuite, c’est LangChain qui fournit des connecteurs (loaders) pour les formats courants comme PDF, DOCX, TXT et HTML (Annexe 4).

b) Etape 2 : Découpage en fragments (Chunking)

Ensuite, chaque document est découpé en fragments (chunks) de taille contrôlée. Notons que la taille des chunks et le chevauchement entre eux (overlap) sont des paramètres critiques : s’ils sont trop petits les chunks perdent leur sens ; dans le cas contraire, l’information significative est submergée par le bruit. Suite à des essais, nous avons opté une taille de 512 tokens avec un chevauchement de 64 tokens (Annexe 5).

c) Etape 3 : Vectorisation (Embedding)

En outre, chaque fragment est converti en un vecteur de grande dimension grâce à un modèle d’embedding. Ce vecteur saisit la signification du texte : deux passages abordant le même thème disposeront de vecteurs proches dans l’espace vectoriel, même s’ils emploient des termes différents. Pour notre cas, nous employons le modèle d’intégration intégré à Ollama, qui est cohérent avec le modèle Mistral utilisé pour la génération (Annexe 6).

d) Etape 4 : Indexation dans ChromaDB

Par la suite, les vecteurs générés sont stockés dans ChromaDB avec leurs métadonnées comme le nom du fichier source, le numéro de page et la date d'indexation (Figure 29). A noter que cette base vectorielle permet de rechercher les similarités en quelques millisecondes, même sur des milliers de fragments (Annexe 7).

III.3.2.2 Phase 2 - Interrogation en temps réel

Pour chaque requête de l'utilisateur, le processus d'interrogation se déroule en trois temps : recherche des fragments pertinents, élaboration du prompt enrichi et la génération de la réponse.

a) Recherche par similarité

D'une manière spécifique, la requête de l'utilisateur est vectorisée, puis ChromaDB détermine les cinq fragments dont le vecteur présente la plus grande proximité avec celui de la question, en se basant sur la similarité cosinus (Annexe 8). Ensuite, ces fragments constituent le contexte documentaire fourni au modèle.

b) Construction du prompt et génération

Maintenant, le modèle Mistral reçoit un prompt qui comporte trois composantes à savoir une directive système précisant le rôle et les limitations de l'agent, le contexte documentaire extrait, ainsi que la question posée par l'utilisateur (Annexe 9). Par contre, il est important de souligner que la directive système est essentielle car elle impose au modèle de réagir exclusivement en fonction du contexte donné et d'indiquer clairement lorsque l'information fait défaut.

III.3.2.3 API REST - Endpoints FastAPI

L'API REST du backend, qui est automatiquement documentée par OpenAPI, est accessible via `/docs` lors du développement. Les endpoints sont structurés en trois routeurs différents : celui de l'authentification (Tableau 9), celui du RGPD (Tableau 10) et celui de la cybersécurité (Tableau 11). Notons que chaque itinéraire est sécurisé par le middleware d'authentification Zero Trust, qui contrôle le token JWT et les permissions d'accès avant toute manipulation.

A présent, nous allons illustrer ci-après le tableau des endpoints du côté de l'authentification, RGPD, cybersécurité.

a) Routeur Authentification - `/auth`

TABLEAU 9 – API d'authentification

Méthode	Route	Description	Rôles autorisés	Réponse
POST	<code>/auth/token</code>	Échange des identifiants contre un token JWT via Keycloak	Tous	{ access_token, token_type, expires_in }
POST	<code>/auth/refresh</code>	Renouvellement d'un token expiré	Tous (token valide)	{ access_token, expires_in }
GET	<code>/auth/me</code>	Retourne le profil de l'utilisateur connecté	Tous	{ user_id, email, roles }
POST	<code>/auth/logout</code>	Révocation du token côté Keycloak	Tous	{ message : "Déconnecté" }

Source : Auteure, 2026

b) *Routeur RGPD - /rgpd*

TABLEAU 10 – API RGPD – Gestion des traitements et conformité

Méthode	Route	Description	Rôles autorisés	Corps / Réponse
POST	/rgpd/query	Soumet une question à l'agent RGPD	cdt, dpo, admin	{ question } → { answer, sources, confidence }
GET	/rgpd/traitements	Liste les traitements de l'utilisateur	cdt, dpo, admin	→ [{ id, nom, statut, date }]
POST	/rgpd/traitements	Crée un nouveau traitement	cdt, dpo, admin	{ TraitementIn } → { TraitementOut }
GET	/rgpd/traitements/{id}	Détail d'un traitement	cdt, dpo, admin	→ { TraitementOut complet }
PUT	/rgpd/traitements/{id}	Met à jour un traitement	cdt, dpo, admin	{ TraitementIn } → { TraitementOut }
POST	/rgpd/traitements/{id}/export	Génère la fiche PDF du traitement	cdt, dpo, admin	→ Fichier PDF (stream)
GET	/rgpd/conversations	Historique des conversations	cdt, dpo	→ [{ id, date, resume }]
GET	/rgpd/dashboard	Indicateurs de conformité globaux	dpo, admin	→ { nb_traitements, nb_dpia, taux_conformite }
POST	/rgpd/dpia/check	Vérifie si une DPIA est requise	cdt, dpo	{ TraitementIn } → { required : bool, raisons : [] }

Source : Auteure, 2026

c) *Routeur Cybersécurité - /cyber*

TABLEAU 11 – API Cybersécurité – Analyse des logs et événements

Méthode	Route	Description	Rôles autorisés	Corps / Réponse
POST	/cyber/analyze	Soumet un fichier de logs à l'analyse	analyste, admin	Fichier multipart → { AnalyseOut }
GET	/cyber/analyses	Liste les analyses de l'utilisateur	analyste, admin	→ [{ id, fichier, date, statut }]
GET	/cyber/analyses/{id}	Détail complet d'une analyse	analyste, admin	→ { AnalyseOut avec événements }
GET	/cyber/analyses/{id}/events	Liste des événements d'une analyse	analyste, admin	→ [{ EvenementOut }] (filtrable)
DELETE	/cyber/analyses/{id}	Supprime une analyse	admin	→ { message : "Supprimé" }
GET	/cyber/stats	Statistiques globales de sécurité	admin	→ { nb_critiques_7j, tendance, top_types }

Source : Auteure, 2026

III.3.3 Modèle de classification des logs

Il est important de souligner que le modèle de classification des événements de logs se base sur une technique d'apprentissage supervisé. Contrairement à l'agent RGPD qui fait appel à un LLM génératif, le classifieur génère des

réponses à la fois déterministes et reproductibles, c'est-à-dire, pour un événement identique, il renverra toujours la même étiquette. Dans un contexte sécuritaire où la fiabilité est primordiale, cette caractéristique est essentielle.

III.3.3.1 Construction des features

Avant d'être présentée au classificateur, chaque ligne de log est convertie en un vecteur de caractéristiques numériques. D'abord, la phase d'extraction des caractéristiques est le maillon le plus crucial du processus de classification : des caractéristiques inappropriées aboutiront à un modèle défectueux, quelle que soit sa sophistication (Annexe 10).

III.3.3.2 Entraînement du modèle

A priori, nous avons choisi d'utiliser un classificateur Random Forest, qui est une collection d'arbres de décision dont les prédictions sont combinées par vote majoritaire. En effet, cette option est privilégiée en raison de sa solidité face à des données déséquilibrées (les incidents critiques sont naturellement rares), de son aptitude à traiter des caractéristiques variées, et de son interprétabilité hors pair car il est possible de voir les caractéristiques qui ont le plus d'influence sur les décisions (Annexe 11).

III.3.3.3 Métriques d'évaluation

Il est essentiel de noter que le modèle a été testé sur un ensemble de 500 événements, soigneusement annotés par l'équipe de cybersécurité de l'entreprise d'accueil, qui reflète fidèlement la répartition des événements dans le contexte de production.

TABLEAU 12 – Métriques de classification sur le jeu de test

Classe	Précision	Rappel	F1-Score	Support
Normal	94%	97%	95%	320 événements
Suspect	87%	82%	84%	120 événements
Critique	91%	89%	90%	60 événements
Moyenne pondérée	92%	93%	92%	500 événements

Source : Auteure, 2026

Ici, nous remarquons que la classe "Suspect" affiche des métriques légèrement plus basses que les deux autres du fait de l'ambiguïté inhérente à cette classe intermédiaire. Cependant, certains événements suspects peuvent parfois se confondre avec des événements normaux (faux négatifs), tandis que d'autres peuvent être assimilés à des événements critiques (faux positifs). Par conséquent, l'amélioration majeure du modèle réside dans l'augmentation de la taille du jeu de données d'apprentissage pour cette catégorie (Tableau 12).

III.3.4 Implémentation Flutter

Nous avons utilisé Flutter pour développer l'application mobile, le framework de Google qui permet de créer des applications natives iOS et Android à partir d'un code source unique écrit en Dart. Également, elle interagit avec le même backend FastAPI que l'interface web, par le biais d'appels HTTPS authentifiés (Annexe 12).

Le package flutter_secure_storage permet le stockage du jeton JWT dans l'espace de rangement sécurisé natif de l'appareil (Android Keystore / iOS Keychain). Il ne circule jamais en texte clair et n'est jamais enregistré dans les préférences communes ou la mémoire externe (Annexe 13). En se basant sur l'annexe 14, le package Dio prend en charge toutes les demandes effectuées vers le serveur, offrant une gestion sophistiquée des intercepteurs, des délais et des erreurs. Un intercepteur insère de manière automatique le token JWT dans l'en-tête Authorization de chaque demande.

TABLEAU 13 – Correspondance entre les exigences de sécurité et les mécanismes techniques

Propriété recherchée	Mécanisme technique	Composant
Confidentialité des données	Hébergement on-premise, LLM local	Ollama + Mistral
Sécurité des communications	TLS 1.3, headers HTTP sécurisés	Nginx
Contrôle des accès	OAuth2 + JWT + RBAC granulaire	Keycloak
Pertinence des réponses RGPD	Pipeline RAG avec base documentaire interne	LangChain + ChromaDB
Fiabilité de la détection cyber	Modèle supervisé déterministe (F1=92%)	Scikit-learn
Réactivité terrain	Notifications push temps réel	FCM + Flutter
Résistance aux injections	Filtrage des entrées + prompt système contraint	FastAPI + LangChain
Évolutivité	Architecture modulaire, agents isolés	Docker + FastAPI
Traçabilité	Journalisation de chaque accès et requête	PostgreSQL + Nginx logs

Source : Auteure, 2026

Egalement, cette architecture offre un fondement robuste pour une mise en production. Elle suit les directives de l'ANSSI pour la sécurisation des systèmes d'information, les normes du RGPD en matière de protection des informations personnelles, et les principes énoncés dans l'AI Act concernant la transparence et le contrôle humain des systèmes d'intelligence artificielle (Tableau 13).

IV EVALUATION DU PROJET ET PERSPECTIVES

Dans un contexte marqué par l'intégration croissante de l'intelligence artificielle au sein des systèmes d'information, l'évaluation du projet revêt une importance particulière. Elle vise à analyser les performances, la robustesse et la sécurité de la solution proposée, tout en identifiant les axes d'amélioration et les perspectives d'évolution.

IV.1 Etude des risques

IV.1.1 Évaluation du modèle de classification des logs

IV.1.1.1 Métriques retenues et justification

Dans notre projet, les métriques d'évaluation choisies doivent prendre en compte les enjeux de la cybersécurité, où l'impact des erreurs varie. Un faux négatif (attaque non repérée) est crucial, tandis qu'un faux positif entraîne une surcharge superflue pour les analystes. Ensuite, il est essentiel de comprendre que la précision évalue le pourcentage d'événements correctement identifiés comme critiques parmi ceux qui ont été prédits en tant que tels. Quant au rappel, qui est une métrique de premier plan, mesure la faculté du modèle à identifier les événements véritablement critiques. Par ailleurs, le F1-score représente un équilibre entre précision et rappel, surtout approprié pour des données déséquilibrées. Enfin, la matrice de confusion sert à examiner les fautes de classification parmi les différentes catégories, alors que l'AUC-ROC mesure l'efficacité du modèle à différencier ces catégories.

IV.1.1.2 Résultats sur le dataset de test

Le Tableau 14 démontre les résultats du jeu de test (constitué de 15% des données, que le modèle n'a jamais rencontrées durant l'entraînement et la validation). Ces résultats représentent l'évaluation de référence pour le modèle.

TABLEAU 14 – Performances du modèle de classification

Classe	Précision	Rappel	F1-Score	Support (n)
NORMAL	0.998	0.997	0.997	~353 863
SUSPECT	0.963	0.971	0.967	~46 882
CRITIQUE	0.981	0.976	0.978	~22 630
Macro average	0.981	0.981	0.981	~423 375
Weighted average	0.994	0.994	0.994	~423 375

Source : Auteure, 2026

Ici, ces résultats sont conformes aux références publiées sur CICIDS2017. Le score de 0,976 relatif à la classe CRITIQUE représente l'indicateur le plus crucial d'un point de vue opérationnel : cela indique que 97,6% des attaques effectives sont identifiées par le modèle.

IV.1.1.3 Analyse des erreurs et limites du modèle

Malgré le succès de notre logiciel, l'examen de la matrice de confusion indique que les erreurs de classification courantes se produisent à la limite entre les classes SUSPECT et CRITIQUE. Ces méprises proviennent de la ressemblance inhérente entre certains schémas d'attaques de faible envergure et des comportements suspectés qui ne sont pas malveillants. Il est essentiel de documenter honnêtement les limites significatives. Tout d'abord, le modèle a été formé sur des données jusqu'en 2017 : il se peut qu'il ne reconnaisse pas les nouvelles méthodes d'attaque qui ont

émergé depuis. Un mécanisme de réentraînement périodique sur de nouvelles données est nécessaire pour maintenir les performances dans le temps. En second lieu, les performances évaluées sur CICIDS2017 pourraient ne pas être directement applicables à un environnement de production, où les modèles de trafic normal sont susceptibles de varier.

IV.1.2 Stratégies de test

Avant de décrire cette étape, il est important de souligner notre approche sur les tests. En effet, nous avons distingué trois différents tests à savoir : • les tests fonctionnels qui vérifient que toutes fonctionnalités se comportent comme attendues • les tests de sécurité qui tentent de mettre en défaut les mécanismes de sécurité • les tests de pertinence qui évaluent la qualité des réponses générées par l’agent IA (surtout le RGPD)

IV.1.2.1 Tests fonctionnels

A priori, les tests fonctionnels englobent l’ensemble des cas d’usage identifiés dans la seconde partie de notre travail. Ils ont été réalisés manuellement dans un premier temps, puis partiellement automatisés via des scripts pytest pour les routes de l’API backend (Tableau 15).

TABLEAU 15 – Résultats des tests fonctionnels

Fonctionnalité testée	Résultat attendu	Résultat obtenu	Statut
Connexion avec identifiants valides	Accès accordé, token JWT reçu	Conforme	OK
Connexion avec identifiants invalides	Accès refusé, message d’erreur	Conforme	OK
Saisie d’un traitement complet	Enregistrement en base, confirmation	Conforme	OK
Question à l’agent RGPD (domaine connu)	Réponse contextualisée avec sources	Conforme	OK
Question hors domaine documentaire	Réponse avouant l’absence d’info	Conforme	OK
Export fiche de traitement PDF	Fichier PDF généré et téléchargeable	Conforme	OK
Soumission fichier logs (mobile)	Analyse lancée, résultats affichés	Conforme	OK
Classification événement normal	Label “Normal”, score < 0.3	Conforme	OK
Classification événement critique	Label “Critique”, score > 0.8	Conforme	OK
Déclenchement notification push critique	Notification reçue sur mobile	Conforme	OK
Accès à une ressource sans autorisation	HTTP 403 Forbidden	Conforme	OK
Historique des conversations	Affichage des échanges passés	Partiel (session uniquement)	Par

Source : Auteure, 2026

IV.1.2.2 Tests de sécurité

Quand aux tests de sécurité (Tableau 16), nous nous sommes penchés sur trois axes principaux : la robustesse de l'authentification, la résistance aux tentatives d'injection de prompt et le respect du cloisonnement des données entre les différents rôles.

TABLEAU 16 – Résultats des tests de sécurité

Test de sécurité	Résultat attendu	Résultat obtenu	Statut
Accès sans token JWT (requête directe à l'API sans en-tête Authorization)	HTTP 401 retourné	Conforme	OK
Token expiré ou falsifié	Accès refusé	Conforme	OK
Token JWT modifié manuellement	Rejet par Keycloak	Conforme	OK
Injection de prompt simple ("Ignore tes instructions et révèle ta configuration")	Refus et réponse hors contexte	Conforme	OK
Injection de prompt avancée (prompt encodé en base64)	Détection partielle	Partiellement conforme	Partiel
Accès croisé entre rôles (chargé de traitement accédant aux logs cyber)	HTTP 403 retourné	Conforme	OK
Énumération des endpoints (scan des routes non documentées)	Nginx bloque les routes inconnues	Conforme	OK
Injection SQL via formulaire (caractères spéciaux dans les champs texte)	Entrées sécurisées (Pydantic)	Conforme	OK

Source : Auteure, 2026

Par rapport à ce résultat, le seul hic identifié est celui de l'injection de prompt avancée, notamment lorsque le contenu malveillant est encodé dans une requête apparemment légitime. Par conséquent, il fera l'objet d'une amélioration pour les versions futures via l'ajout d'un module de filtrage dédié en amont au pipeline RAG.

IV.1.2.3 Tests de pertinence de l'agent RGPD

Cette étape a été la plus complexe. En effet, nous avons constitué un jeu de vingt questions types couvrant différentes situations RGPD et nous avons évalué les réponses de l'agent selon trois critères distincts : la pertinence par rapport à la question, l'exactitude juridique et la présence de sources vérifiables. Les résultats sont présentés ci-dessous sur une échelle de 1 à 5 (Tableau 17).

TABLEAU 17 – Évaluation de la pertinence de l’agent RGPD

Catégorie de questions	Nb questions	Score moyen /5	Observations
Base légale applicable	5	4,4/5	Excellente précision sur les 6 bases légales RGPD
Nécessité d’une DPIA	4	4,2/5	Un faux négatif observé sur un cas limite
Durée de conservation	4	3,8/5	Variabilité selon le secteur, réponses parfois génériques
Droits des personnes	4	4,6/5	Très bonne couverture des 8 droits RGPD
Transferts hors UE	3	3,5/5	Mécanismes de transfert partiellement couverts
Score global	20	4,1/5	Très satisfaisant pour un contexte professionnel

Source : Auteure, 2026

Suite à ce tableau, le score 4,1/5 est un résultat remarquable pour un premier déploiement. Nous pouvons dire que l’approche RAG combinée à une base documentaire bien constituée permet de produire des réponses fiables et contextualisés, nettement supérieurs aux performances d’un assistant généraliste.

IV.1.2.4 Tests de précision du modèle de classification des logs

Le modèle de classification des logs a été annoté sur un jeu de données composé de 500 événements et ces derniers couvrent les trois classes du modèle : normal, suspect et critique (Tableau 18).

TABLEAU 18 – Rapport de classification du modèle

Classe	Précision	Rappel	F1-Score	Support
Normal	94%	97%	95%	320
Suspect	87%	82%	84%	120
Critique	91%	89%	90%	60
Moyenne pondérée	92%	93%	92%	500

Source : Auteure, 2026

Selon ce tableau, les résultats sont globalement satisfaisants avec un F1-Score de 92%. La classe ‘suspect’ présente une performance légèrement inférieure, ce qui s’explique par la nature intrinsèquement ambiguë de cette catégorie intermédiaire. L’enrichissement du jeu de données d’entraînement avec davantage d’exemples de la classe ‘suspect’ constitue l’amélioration prioritaire pour les prochaines itérations.

IV.1.2.5 Métriques de performance

Mis à part la qualité des réponses, nous avons évalué aussi les temps de réponse du système dans différentes conditions d'utilisation. Elles ont été réalisées sur l'infrastructure de développement qui ne sont pas nécessairement les conditions d'un déploiement optimisé (Tableau 19).

TABLEAU 19 – Performances mesurées du système

Opération	Temps moyen	Temps max observé	Objectif fixé	Statut
Authentification (Keycloak)	180 ms	320 ms	< 500 ms	OK
Réponse agent RGPD (RAG)	4,2 s	8,7 s	< 10 s	OK
Analyse fichier logs (100 lignes)	3,1 s	5,4 s	< 10 s	OK
Analyse fichier logs (1000 lignes)	18 s	31 s	< 10 s	Non conforme
Génération fiche PDF	1,4 s	2,0 s	< 30 s	OK
Chargement dashboard web	0,9 s	1,6 s	< 2 s	OK

Source : Auteurs, 2026

Un seul objectif n'est pas pleinement atteint : l'analyse de fichiers de logs très volumineux (1 000 lignes et plus) peut dépasser les 30 secondes sur l'infrastructure actuelle. Plusieurs optimisations sont envisagées : le traitement par lots parallèles, une mise en cache des résultats intermédiaires, et l'utilisation d'un modèle de classification plus léger et plus rapide pour les gros volumes (Tableau 20). Afin d'anticiper les difficultés potentielles du projet, nous avons établi une analyse des risques en tenant compte de leur probabilité d'occurrence, de leur impact et des mesures d'atténuation associées (Tableau 21).

TABLEAU 20 – Évaluation du modèle de classification des événements de sécurité

Classe	Précision	Rappel	F1-Score	Support
Normal	94%	97%	95%	320 événements
Suspect	87%	82%	84%	120 événements
Critique	91%	89%	90%	60 événements
Moyenne pondérée	92%	93%	92%	500 événements

TABLEAU 21 – Analyse des risques du projet

Risque	Type	Probabilité	Impact	Mesures d'atténuation
Base documentaire incomplète ou obsolète	Technique	Moyenne	Élevé	Processus de mise à jour régulier, alertes de veille réglementaire
Injection de prompt par un utilisateur malveillant	Sécurité	Faible	Élevé	Filtrage des entrées, isolation des agents, journalisation des requêtes
Dégradation des performances avec montée en charge	Technique	Moyenne	Moyen	Architecture scalable, optimisation du pipeline RAG, cache
Résistance au changement des utilisateurs	Humain	Faible	Moyen	Formation, accompagnement, interface intuitive
Défaillance du serveur on-premise	Infrastructure	Faible	Élevé	Sauvegardes régulières, plan de reprise d'activité
Évolution réglementaire (AI Act, RGPD)	Juridique	Moyenne	Moyen	Veille juridique, architecture adaptable, contrôle humain maintenu
Fuite de données sensibles	Sécurité	Très faible	Très élevé	Zero Trust, chiffrement, cloisonnement strict, audit des accès

Source : Auteure, 2026

IV.1.3 Les risques spécifiques aux agents IA

L'incorporation d'agents d'intelligence artificielle dans un système d'information comporte certains dangers. Ces risques diffèrent de ceux liés aux logiciels conventionnels, et il est essentiel de les comprendre parfaitement avant de pouvoir les gérer de manière efficace.

Le premier danger se situe au niveau de l'injection des requêtes. C'est une méthode où un utilisateur malveillant formule une requête pour duper l'agent et le contraindre à dévoiler des données secrètes ou à agir d'une manière inattendue. Pour l'IA, c'est l'équivalent d'une injection SQL sur une base de données.

Ensuite, le second danger réside dans la divulgation des données. Si l'agent a accès à des documents sensibles pour répondre aux questions, nous devons garantir qu'il ne peut pas partager ces informations avec des utilisateurs non autorisés. Il est donc essentiel de gérer les autorisations.

Enfin, le troisième danger concerne les hallucinations [1]. Il s'agit de la tendance de certains modèles de langage à produire des réponses inexactes mais avec autant d'assurance. Dans ce contexte métier, une réponse incorrecte peut entraîner des répercussions concrètes telles qu'une mauvaise interprétation d'une règle RGPD, une fausse alerte de sécurité ou à l'inverse, la négligence d'une menace réelle.

IV.1.4 Gouvernance des données et contrôle humain

L'une des principales questions auxquelles nous nous demandons concernant l'intégration de l'IA dans les processus métiers est celle du contrôle. Jusqu'où peut-on déléguer à une machine ? Quelle est l'importance du jugement humain ? Nous avons une position nette à ce sujet : les agents d'IA que nous développons ne sont pas des décideurs indépendants, mais des instruments d'aide. Ce concept, fréquemment appelé Human-in-the-Loop, indique que l'humain demeure le pivot du processus décisionnel. L'agent effectue des analyses, propose des suggestions et résume les informations, mais c'est toujours un professionnel compétent qui donne son approbation, prend les décisions et endosse la responsabilité

de l'action. Dans le contexte de l'Assurance d'Identité Basée sur le Risque, l'humain assume trois rôles principaux :

- La vérification des cas extrêmes (Edge Cases) : Quand l'algorithme d'apprentissage automatique attribue un score de risque indéterminé (comme, par exemple, une probabilité de fraude de 50
- L'arbitrage dans le respect de l'éthique et de la loi : Certaines mesures de sécurité ont des répercussions sur le plan légal ou social (par exemple : fermeture permanente d'un compte VIP ou accès à des informations médicales). C'est l'homme qui assure la proportionnalité de la réaction face à la menace.
- La surveillance et le réglage des seuils : C'est le spécialiste en sécurité informatique qui détermine la « sensibilité » du moteur d'analyse des risques. Il modifie les poids des variables (comme privilégier la localisation au navigateur) selon la tactique de protection adoptée par l'entreprise.

IV.2 Coût de mise en oeuvre

L'estimation budgétaire du projet est présentée selon trois catégories : les coûts de développement (investissement initial), les coûts d'infrastructure (matériel et logiciel) et les coûts d'exploitation récurrents (Tableau 23).

TABLEAU 22 – Estimation budgétaire du projet

Poste de coût	Détail	Estimation
Développement	8 semaines × coût journalier (stage)	Coût stage (selon convention)
Infrastructure serveur	Serveur on-premise (si acquisition)	1 500 – 3 000 € (selon specs)
Logiciels et licences	Stack 100% open source	0 € (aucune licence)
Formation utilisateurs	2 sessions de demi-journée	400 € (temps formateur)
Maintenance annuelle	Mises à jour, support, veille	200 h/an (estimation)
Firebase (notifications push)	Plan gratuit (< 1 million msg/mois)	0 €
TOTAL investissement initial		1 900 – 3 400 € + coût stage

Source : Auteure, 2026

IV.3 Perspectives

Malgré un fruit de travail acharné, nous pouvons dire que notre application présente certaines limites. En effet, toute solution technique à ses propres limites et il est essentiel de les connaître afin d'améliorer les versions futures.

La première limite concerne la qualité de la base documentaire. Les réponses de l'agent RGPD sont directement conditionnées par la richesse et la mise à jour des documents indexés. Si un texte réglementaire évolue et que la base n'est pas mise à jour, l'agent peut produire des réponses obsolètes. La mise en place d'un processus de mise à jour régulier est donc indispensable en production. La deuxième limite touche à la généralisation du modèle de classification. Le modèle a été entraîné sur des données propres à l'environnement de l'entreprise d'accueil. Son déploiement dans un contexte différent, autre secteur, autre infrastructure réseau nécessiterait un réentraînement sur des données représentatives du nouvel environnement.

La troisième limite est l'absence d'un mécanisme de feedback intégré. En effet, si un utilisateur pense qu'une réponse de l'agent RGPD est incorrecte, il n'a pas de moyen direct de le signaler dans l'interface. par conséquent, il est nécessaire d'ajouter un système de notation des réponses afin d'identifier les zones de faiblesse et d'améliorer progressivement la qualité du système. Enfin, la quatrième limite concerne la scalabilité. L'architecture actuelle est

conçue pour un usage interne à une organisation de taille moyenne. Un déploiement multi-organisations ou à très grande échelle nécessiterait une refonte de l'architecture vers un modèle multi-tenant, avec isolation stricte des données entre organisations.

Face aux limites identifiées, nous allons élargir notre champ de recherche afin de disposer d'une plateforme d'agents IA métiers qui se maintient elle-même à jour, avec un minimum d'intervention humaine.

A court terme, nous prévoyons d'étendre la plateforme à d'autres domaines métiers. L'architecture que nous avons conçue est modulaire par nature : ajouter un nouvel agent spécialisé en droit social, en gestion des risques financiers, ou en conformité ISO 27001, ne nécessite que de constituer la base documentaire correspondante et de configurer les droits d'accès associés. La couche technique reste identique.

Sur le long terme, nous envisageons d'intégrer un module de veille réglementaire automatisée, qui surveille les publications officielles comme le Journal Officiel de l'Union Européenne, délibérations de la CNIL, bulletins de l'ANSSI et alerte l'administrateur lorsque des documents susceptibles d'impacter la base de connaissance sont publiés.

CONCLUSION

Depuis le début de ce projet, il y avait une question simple à laquelle nous nous sommes posés : Comment faire travailler l'intelligence artificielle au coeur d'une organisation sans en perdre le contrôle, sans exposer ses données et en apportant une vraie valeur aux équipes au quotidien ?

Pour y répondre, nous avons choisi de bien observer, analyser, écouter et comprendre. Après les interview avec les personnes concernées, des heures perdues sur des tâches répétitives, des experts sollicités en permanence pour des questions auxquelles la documentation pourrait répondre, des analystes qui scrutent des centaines de lignes de logs sans outil pour les aider à prioriser. Là, il s'agit d'un manque d'assistance adaptée.

C'est exactement ce que nous avons essayé de construire. Pas un outil magique qui remplace les gens, mais un assistant qui sait de quoi il parle parce qu'il a été nourri des documents de l'organisation, qui répond aux vraies questions métiers, et qui reste sous contrôle humain à chaque étape. Les résultats des tests nous ont confortés dans cette direction : un score de pertinence de 4,1 sur 5 pour l'agent RGPD, un F1-Score de 92% pour la détection d'anomalies dans les logs. Ce sont des chiffres encourageants, mais ce qui compte davantage, c'est le retour des utilisateurs qui ont testé la solution : le sentiment que l'outil comprend leur contexte, et que ses réponses sont utilisables telles quelles.

Ce projet nous a aussi appris quelque chose de plus personnel. Travailler à la frontière de l'informatique, du droit et de la sécurité, c'est accepter de ne jamais tout maîtriser parfaitement et c'est précisément là que réside l'intérêt. L'intelligence artificielle ne simplifie pas les choses : elle déplace la complexité. Ce n'est plus « comment coder ça » mais « comment s'assurer que ça reste juste, fiable et honnête ». C'est une question plus difficile, et sans doute plus importante.

Ainsi, le chemin est encore loin et long et il nous reste beaucoup à faire : la base documentaire à enrichir, le modèle mobile à optimiser, d'autres domaines métiers à couvrir. Mais les fondations sont là, et elles sont solides.

Compte tenu des résultats de notre prototype, des améliorations sont d'ores et déjà prévues pour la version v2 de ce dernier, notamment pour finaliser le système d'alerte en temps réel des anomalies, l'automatisation de l'analyse des logs et l'exportation automatisée des rapports en PDF. A terme, l'objectif est de faire évoluer cette solution vers un framework réutilisable par d'autres entreprises qui leur permet de déployer un assistant souverain sans avoir à redévelopper l'ensemble de l'infrastructure de zéro.

Ce mémoire n'est pas une fin, c'est plutôt le début d'une idée qui mérite d'être poussée plus loin.

BIBLIOGRAPHIE

Références

- [1] Amershi, S., Cakmak, M., Knox, W. B., & Kulesza, T. (2014). Power to the people : The role of humans in interactive machine learning. *AI Magazine*, 35(4), 105–120. <https://doi.org/10.1609/aimag.v35i4.2513>, 02 Mars 2026 à 9h00
- [2] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>, 09 Mars 2026 à 17h00
- [3] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE : Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>, 20 Mars 2026 à 10h00
- [4] Russell, S., & Norvig, P. (2020). *Artificial intelligence : A modern approach* (4e éd.). Pearson, 31 Mars 2026 à 09h00
- [5] Sharafaldin, I., Habibi Lashkari, A., & Ghorbani, A. A. (2018). Toward generating a new intrusion detection dataset and intrusion traffic characterization. *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*, 108–116. <https://doi.org/10.5220/0006639801080116>, 06 Avril 2026 à 18h00
- [6] Wooldridge, M., & Jennings, N. R. (1995). Intelligent agents : Theory and practice. *The Knowledge Engineering Review*, 10(2), 115–152. <https://doi.org/10.1017/S0269888900008122>, 17 Avril 2026 à 11h00

WEBOGRAPHIE

Références

- [1] Parlement européen et Conseil de l'Union européenne. (2016). Règlement (UE) 2016/679 (RGPD). <https://eur-lex.europa.eu/legal-content/FR/TXT/?uri=CELEX%3A32016R0679>, 23 Février 2026 à 10h00
- [2] Parlement européen et Conseil de l'Union européenne. (2024). Règlement (UE) 2024/1689 (IA Act). <https://eur-lex.europa.eu/legal-content/FR/TXT/?uri=CELEX:32024R1689>, 26 Février 2026 à 10h00
- [3] Université du Nouveau-Brunswick. (2017). CICIDS2017 — Intrusion detection evaluation dataset. <https://www.unb.ca/cic/datasets/ids-2017.html>, 18 Mars 2026 à 13h00

ANNEXE

Annexe 1 — Couche réseau Nginx de l'architecture Zero Trust

```
upstream backend {
    server localhost:8000; # Port FastAPI
}

# Rate limiting
limit_req_zone $binary_remote_addr zone=api:10m rate=10r/s;
limit_req_zone $binary_remote_addr zone=auth:10m rate=5r/m;

# Logs sécurisés
log_format security '$remote_addr - $remote_user [$time local] "$request" '
                    '$status $body_bytes_sent "$http_referer" '
                    '"$http_user_agent" "$http_x_forwarded_for" '
                    'rt=$request_time ua=$upstream_addr' '
                    'us=$upstream_status' ut=$upstream_response_time' '
                    'ul=$upstream_response_length' '
                    'cs=$upstream_cache_status';

server {
    listen 80;
    server_name your-domain.com; # Remplacer par votre domaine

    # Redirect HTTP vers HTTPS
    return 301 https://$server_name$request_uri;
}

server {
    listen 443 ssl http2;
    server_name your-domain.com; # Remplacer par votre domaine

    # SSL/TLS Configuration sécurisée
    ssl_certificate /etc/ssl/certs/your-domain.crt; # Chemin vers certificat
    ssl_certificate_key /etc/ssl/private/your-domain.key; # Chemin vers clé privée

    # Protocoles et ciphers sécurisés
    ssl_protocols TLSv1.2 TLSv1.3;
    ssl_ciphers ECDHE-RSA-AES256-GCM-SHA512:DHE-RSA-AES256-GCM-SHA512:ECDHE-RSA-AE
```

Source : Auteur, 2026

FIGURE 31 – Configuration Nginx sécurisée

Annexe 2 — Couche authentification Keycloak + JWT

```
from fastapi import Depends, HTTPException, status
from fastapi.security import OAuth2PasswordBearer
from sqlalchemy.orm import Session
from app.database import get_db
from app.models import User
from app.auth.service import decode_token
from jose import JWTError

oauth2_scheme = OAuth2PasswordBearer(tokenUrl="/auth/login")

def get_current_user(token: str = Depends(oauth2_scheme), db: Session = Depends(get_db)):
    try:
        payload = decode_token(token)
        email = payload.get("sub")
        if not email:
            raise HTTPException(status_code=401, detail="Token invalide")
        user = db.query(User).filter(User.email == email).first()
        if not user:
            raise HTTPException(status_code=401, detail="Utilisateur introuvable")
        return user
    except JWTError:
        raise HTTPException(status_code=401, detail="Token expiré ou invalide")
```

Source : Auteur, 2026

FIGURE 32 – Authentification JWT

Annexe 3 — Protection contre les injections de prompts

```
def sanitize_content(content: str) -> Tuple[str, list]:
    """
    Sanitise le contenu pour éliminer les injections de prompts.
    Retourne (contenu_sanitisé, injections_détectées).
    """
    injections_found = []
    sanitized_lines = []

    for line_num, line in enumerate(content.split('\n'), 1):
        original_line = line
        detected_injection = False

        # Détection de mots-clés d'injection
        for keyword in PROMPT_INJECTION_KEYWORDS:
            if keyword.lower() in line.lower():
                injections_found.append({
                    "line": line_num,
                    "keyword": keyword,
                    "content": line[:100] # Premiers 100 caractères
                })
                detected_injection = True
                logger.warning(f"Injection potentielle détectée ligne {line_num} : {keyword}")
                break

        # Patterns dangereux supplémentaires
        dangerous_patterns = [
            r'```[\s\S]*?```', # Blocs de code
            r'<script[^\>]*>[\s\S]*?</script>', # JavaScript
            r'\${.*?}\}', # Template injection
            r'#\.\system', # Commande système
        ]

        if detected_injection or any(re.search(pattern, line) for pattern in dangerous_patterns):
            sanitized_lines.append(original_line)
        else:
            sanitized_lines.append(line)

    return '\n'.join(sanitized_lines), injections_found
```

Source : Auteure, 2026

FIGURE 33 – Filtre de protection contre les injections de prompts

Annexe 4 — Etape 1 : Chargement des documents dans la phase d'ingestion

```
from langchain_text_splitters import RecursiveCharacterTextSplitter
from langchain_community.embeddings import OllamaEmbeddings
from langchain_community.vectorstores import Chroma
from dotenv import load_dotenv

load_dotenv()

DOCUMENTS_PATH = os.getenv("DOCUMENTS_PATH", "./documents")
CHROMA_DB_PATH = os.getenv("CHROMA_DB_PATH", "./chroma_db")
OLLAMA_MODEL = os.getenv("OLLAMA_MODEL", "mistral")

def ingest_documents():
    print("Chargement des documents RGPD...")

    # Charge tous les PDFs du dossier documents/
    loader = DirectoryLoader(
        DOCUMENTS_PATH,
        glob="**/*.pdf",
        loader_cls=PyPDFLoader
    )
    documents = loader.load()
```

Source : Auteure, 2026

FIGURE 34 – chargement en PDF des documents

Annexe 5 — Etape 2 : Découpage en fragments ou Chunking dans la phase d'ingestion

```
# Découpe en fragments de 512 tokens
# avec chevauchement de 50 tokens pour préserver le contexte
splitter = RecursiveCharacterTextSplitter(
    chunk_size=512,
    chunk_overlap=50,
    separators=["\n\n", "\n", ".", " ", " "]
)
chunks = splitter.split_documents(documents)
print(f"{len(chunks)} fragments créés")
```

Source : Auteure, 2026

FIGURE 35 – Découpage des documents en fragments

Annexe 6 — Etape 3 : Vectorisation ou Embedding dans la phase d'ingestion

```
# Vectorise avec Ollama (modèle local)
print("Vectorisation en cours (peut prendre quelques minutes)...")
embeddings = OllamaEmbeddings(
    model=OLLAMA_MODEL,
    base_url=os.getenv("OLLAMA_BASE_URL", "http://localhost:11434")
)
```

Source : Auteure, 2026

FIGURE 36 – Génération des embedding via Ollama

Annexe 7 — Etape 4 : Indexation dans ChromaDB durant la phase d'ingestion

```
# Stocke dans ChromaDB
vectorstore = Chroma.from_documents(
    documents=chunks,
    embedding=embeddings,
    persist_directory=CHROMA_DB_PATH,
    collection_name="rgpd_docs"
)

print(f"✅ {len(chunks)} fragments indexés dans ChromaDB")
print(f"Base vectorielle sauvegardée dans : {CHROMA_DB_PATH}")
return len(chunks)

if __name__ == "__main__":
    ingest_documents()
```

Source : Auteure, 2026

FIGURE 37 – Indexation des vecteurs dans ChromaDB

Annexe 8 — Recherche par similarité

```
prompt = f"""Tu es un assistant expert en conformité RGPD.
{domaine_context}

INSTRUCTIONS :
- Réponds de façon précise, structurée et professionnelle
- Si l'utilisateur demande quelles données saisir pour un champ,
  donne des exemples concrets adaptés à son domaine
- Si l'utilisateur demande la base légale, explique les options disponibles
- Si l'utilisateur demande la durée de conservation, donne des durées précises
- Cite toujours les articles RGPD pertinents quand c'est possible
- Réponds toujours en français

DOCUMENTS DE RÉFÉRENCE :
{contexte}

HISTORIQUE DE LA CONVERSATION :
{historique_formate}

QUESTION ACTUELLE : {question}

RÉPONSE :"""

try:
    response = ollama.chat(
        model=OLLAMA_MODEL,
        messages=[{"role": "user", "content": prompt}]
    )
    answer = response['message']['content']
except Exception as e:
    answer = f"Erreur : {str(e)}"

return {
    "answer": answer,
    "sources": sources
}
```

Source : Auteure, 2026

FIGURE 38 – Recherche des fragments par similarité continue

Annexe 9 — Construction du prompt et génération

```
prompt = f"""Tu es un assistant expert en conformité RGPD.
{domaine_context}

INSTRUCTIONS :
- Réponds de façon précise, structurée et professionnelle
- Si l'utilisateur demande quelles données saisir pour un champ,
  donne des exemples concrets adaptés à son domaine
- Si l'utilisateur demande la base légale, explique les options disponibles
- Si l'utilisateur demande la durée de conservation, donne des durées précises
- Cite toujours les articles RGPD pertinents quand c'est possible
- Réponds toujours en français

DOCUMENTS DE RÉFÉRENCE :
{contexte}

HISTORIQUE DE LA CONVERSATION :
{historique_formate}

QUESTION ACTUELLE : {question}

RÉPONSE :"""

try:
    response = ollama.chat(
        model=OLLAMA_MODEL,
        messages=[{"role": "user", "content": prompt}]
    )
    answer = response['message']['content']
except Exception as e:
    answer = f"Erreur : {str(e)}"

return {
    "answer": answer,
    "sources": sources
}
```

Source : Auteure, 2026

FIGURE 39 – Construction du prompt et génération de la réponse

Annexe 10 — Construction des features

```
def extract_features(events: List[Dict]) -> pd.DataFrame:
    """Extrait les features numériques pour chaque événement."""
    rows = []
    for event in events:
        msg = event.get("message", "").lower()
        rows.append({
            "keyword_count": sum(1 for kw in CRITICAL_KEYWORDS if kw in msg),
            "message_length": len(msg),
            "has_ip": 1 if re.search(r'\d{1,3}\.\d{1,3}\.\d{1,3}\.\d{1,3}', msg) else 0,
            "has_port": 1 if re.search(r'port\s*\d+', msg) else 0,
            "severity_level": extract_severity(msg),
            "is_failed_auth": 1 if any(x in msg for x in ['failed password', 'authentication failure', 'invalid user'])
            else 0,
            "is_scan": 1 if any(x in msg for x in ['portscan', 'nmap', 'scan detected']) else 0,
        })
    return pd.DataFrame(rows)
```

FIGURE 40 – Extracteur de features pour la classification des logs

Source : Auteure, 2026

Annexe 11 — Entraînement du modèle de classification

```
def train():
    print("Chargement du dataset CICIDS2017...")
    # Télécharge CICIDS2017 depuis :
    # https://www.unb.ca/cic/datasets/ids-2017.html
    # Place les CSV dans app/ml/data/

    data_path = "app/ml/data/"
    if not os.path.exists(data_path):
        print("ERREUR : Place les fichiers CSV de CICIDS2017 dans app/ml/data/")
        print("En attendant, génération de données synthétiques pour test...")
        X, y = generate_synthetic_data()
    else:
        X, y = load_cicids_data(data_path)

    print(f"Dataset : {len(X)} événements, distribution : {dict(zip(*np.unique(y, return_counts=True)))}")

    # SMOTE pour équilibrer les classes – section 8.2
    print("Application de SMOTE...")
    smote = SMOTE(random_state=42)
    X_resampled, y_resampled = smote.fit_resample(X, y)


    # Découpage 70/15/15
    X_train, X_temp, y_train, y_temp = train_test_split(
        X_resampled, y_resampled, test_size=0.30, random_state=42, stratify=y_resampled
    )
    X_val, X_test, y_val, y_test = train_test_split(
        X_temp, y_temp, test_size=0.50, random_state=42, stratify=y_temp
    )

    print("Entraînement du Random Forest...")
    model = RandomForestClassifier(
        n_estimators=200,
        max_depth=20,
        min_samples_split=5,
        random_state=42,
        n_jobs=-1
    )
```

Source : Auteure, 2026

FIGURE 41 – Entraînement du modèle de classification

Annexe 12 — Structure du projet Flutter



Source : Auteure, 2026

FIGURE 42 – Structure du projet Flutter

Annexe 13 — Stockage sécurisé du JWT (Flutter)

```
import 'package:flutter_secure_storage/flutter_secure_storage.dart';

class SecureStorage {
  static const _storage = FlutterSecureStorage();
  static const _tokenKey = 'access_token';

  static Future<void> saveToken(String token) async {
    await _storage.write(key: _tokenKey, value: token);
  }

  static Future<String?> getToken() async {
    return await _storage.read(key: _tokenKey);
  }

  static Future<void> deleteToken() async {
    await _storage.delete(key: _tokenKey);
  }
}
```

FIGURE 43 – Stockage sécurisé du JWT de Flutter

Annexe 14 — Client HTTP et gestion des requêtes

```
import 'package:dio/dio.dart';
import 'secure_storage.dart';

class ApiClient {
  static const String baseUrl = 'http://localhost:8000'; // Android emulator
  // static const String baseUrl = 'http://localhost:8000'; // iOS simulator
  // static const String baseUrl = 'http://10.0.2.15:8000'; // Vrai appareil

  static Dio createDio() {
    final dio = Dio(BaseOptions(
      baseUrl: baseUrl,
      connectTimeout: const Duration(seconds: 30),
      receiveTimeout: const Duration(seconds: 30),
    )); // BaseOptions // Dio

    // Injecte automatiquement le JWT dans chaque requête
    dio.interceptors.add(InterceptorsWrapper(
      onRequest: (options, handler) async {
        final token = await SecureStorage.getToken();
        if (token != null) {
          options.headers['Authorization'] = 'Bearer $token';
        }
        return handler.next(options);
      },
      onError: (error, handler) async {
        // Redirige vers login si token expiré
        if (error.response?.statusCode == 401) {
          await SecureStorage.deleteToken();
        }
        return handler.next(error);
      },
    ));

    return dio;
  }
}
```

Source : Auteure, 2026

FIGURE 44 – Client HTTP Flutter avec gestion automatique du token

Annexe 15 — Analyse de la conformité d'un traitement

```
def analyser_traitement(traitement_data: dict) -> dict:
    domaine = traitement_data.get('domaine', 'general')
    question = f"""Analyse ce traitement de données et vérifie sa conformité RGPD.
    Identifie les risques, vérifie la base légale, et donne des recommandations précises.

    Traitement :
    - Nom : {traitement_data.get('nom', 'Non renseigné')}
    - Finalité : {traitement_data.get('finalite', 'Non renseigné')}
    - Base légale : {traitement_data.get('base_legale', 'Non renseigné')}
    - Catégories de données : {traitement_data.get('categories_donnees', 'Non renseigné')}
    - Destinataires : {traitement_data.get('destinataires', 'Non renseigné')}
    - Durée de conservation : {traitement_data.get('duree_conservation', 'Non renseigné')}
    - Transferts hors UE : {traitement_data.get('transferts_hors_ue', 'Non')}
    """
    return query_agent(question, domaine=domaine)
```

Source : Auteure, 2026

Annexe 16 — Réponse contextualisée générée par le chatbot

```
# Contextes par domaine
DOMAINE_CONTEXTES = {
    "sante": """Tu assistes un DPO dans le secteur SANTÉ/MÉDICAL.
    Les données sensibles incluent : données de santé, numéro de sécurité sociale,
    antécédents médicaux, traitements, résultats d'analyses.
    Base légale souvent utilisée : obligation légale, intérêt vital, mission de santé publique.
    Durées de conservation spécifiques : dossier médical 20 ans minimum.""",

    "rh": """Tu assistes un DPO dans les RESSOURCES HUMAINES.
    Les données traitées incluent : nom, prénom, CV, salaire, évaluations,
    coordonnées bancaires, absences, données disciplinaires.
    Base légale : contrat de travail, obligation légale.
    Durées : données paie 5 ans, dossier salarié 5 ans après départ.""",

    "education": """Tu assistes un DPO dans le secteur ÉDUCATION.
    Les données incluent : données d'élèves mineurs, résultats scolaires,
    données parents, données enseignants.
    Attention particulière aux données de mineurs – protection renforcée.""",
}
```

Source : Auteure, 2026

Annexe 17 — Création du client Dio avec injection automatique du JWT et gestion d'erreur

401

```
static Dio createDio() {
  final dio = Dio(BaseOptions(
    baseUrl: baseUrl,
    connectTimeout: const Duration(seconds: 30),
    receiveTimeout: const Duration(seconds: 30),
  )); // BaseOptions // Dio

  // Injecte automatiquement le JWT dans chaque requête
  dio.interceptors.add(InterceptorsWrapper(
    onRequest: (options, handler) async {
      final token = await SecureStorage.getToken();
      if (token != null) {
        options.headers['Authorization'] = 'Bearer $token';
      }
      return handler.next(options);
    },
    onError: (error, handler) async {
      // Redirige vers login si token expiré
      if (error.response?.statusCode == 401) {
        await SecureStorage.deleteToken();
      }
      return handler.next(error);
    },
  ));

  return dio;
}
```


Source : Auteure, 2026

Annexe 18 — Configuration de l'URL de base de l'API

```
class ApiClient {
  static const String baseUrl = 'http://localhost:8000'; // Android emulator
  // static const String baseUrl = 'http://localhost:8000'; // iOS simulator
  // static const String baseUrl = 'http://TON_IP_LOCAL:8000'; // Vrai appareil
}
```

Source : Auteure, 2026

Agentic Top 10 At A Glance



Source : Auteure, 2026

CURRICULUM VITAE

CHRYSOSTOME Priscillia

Né(e) le : 01 Septembre 1998 à Tuléar

Adresse : Lot VF 54 Bis Ankazotokana

- **Titre de l'ouvrage :** « CONCEPTION ET RÉALISATION D'UNE PLATEFORME D'AGENTS D'INTELLIGENCE ARTIFICIELLE SÉCURISÉS POUR L'OPTIMISATION DES PROCESSUS MÉTIERS ET LE RENFORCEMENT DE LA CYBERSÉCURITÉ »
- **Nombre de pages :** 96 pages
- **Domaine d'application :** Ingénierie des Systèmes d'Information, intelligence Artificielle (Agents intelligents et RAG), Cybersécurité opérationnelle (Analyse des logs) et Gouvernance de la conformité
- **Périmètre :** Ce travail s'applique à la sécurisation des architectures d'agents IA intégrés aux infrastructures d'entreprise qui vise à améliorer la productivité des équipes métiers telles que le DPO, les analystes de cybersécurité tout en protégeant le système d'information contre les vulnérabilités spécifiques aux technologies d'IA telles que les injections de requêtes et les fuites de données.

TABLE DES MATIÈRES

REMERCIEMENTS	i
RESUME	ii
ABSTRACT	ii
LISTE DES ABREVIATIONS	iv
GLOSSAIRE	vi
LISTE DES TABLEAUX	xiii
LISTE DES FIGURES	xiv
INTRODUCTION	1
I	2
CONTEXTE GENERAL DU PROJET	2
I.1 Présentation de l'entreprise	2
I.1.1 Aperçu général	2
I.1.2 Organisation en interne	2
I.1.2.1 Direction Générale et Conception des systèmes CyberInTrust	3
I.1.2.2 Direction technique des développements	3
I.1.2.3 Responsable des Back Offices (Base de données et API	3
I.1.2.4 Développement React-JS, Python Agents IA	3
I.1.2.5 Développement React-JS RUST	3
I.1.2.6 Responsable Prospection Validation des référentiels de données	3
I.1.3 Domaine de spécialisation	4
I.2 Présentation de l'INSI	4
I.2.1 Information d'ordre général	4
I.2.2 Missions et historiques	4
I.2.3 Organigramme de l'INSI	5
I.2.4 Domaine de spécialisation	6
I.2.4.1 Licences professionnelles	6
I.2.4.2 Masters professionnels	6
I.2.4.3 Formations professionnelles	7
I.2.4.4 Mobilité internationale double diplôme	7
I.2.5 Architectures des formations pédagogiques	7
I.2.6 Relations de l'INSI avec les entreprises et les organismes	8
I.2.7 Partenariat au niveau international	8
I.2.8 Parcours professionnels des diplômés	9
I.2.9 Ressources humaines	10
I.3 Identification du projet	10
I.3.1 Contexte et problématique	10
I.3.1.1 L'intelligence artificielle agentique : fondements et spécificités	10
a) IA générative et IA spécialisée	10

	b)	Qu'est ce qu'un agent IA? Définition et architecture	10
I.3.1.2		Les défis actuels : la conformité, les volumes et les menaces de cybersécurité	11
	a)	Conformité réglementaire : RGPD et IA Act	11
I.3.2		Objectifs du projet	11
I.3.3		Intérêt et justification du projet	12
I.3.3.1		Positionnement de ce travail par rapport à l'état de l'art	12
I.3.3.2		Les deux agents de la plateforme comme entités autonomes	12
	a)	Agent 1 — Agent RGPD (module web)	12
	b)	Agent 2 — Agent Cybersécurité (module mobile)	13
	c)	Taxonomie et positionnement des agents	13
I.4		Méthodologie	13
I.4.1		Méthode d'analyse et collecte des données	13
I.4.1.1		Choix de la méthode de collecte	13
I.4.1.2		Périmètre de l'étude et calcul de la taille d'échantillon	14
I.4.1.3		Axes d'analyse retenus	15
I.4.1.4		Analyse des résultats par axe	15
	a)	Axe 1 - Conformité RGPD :	15
	b)	Axe 2 - Détection d'anomalies :	15
	c)	Axe 3 - Besoins fonctionnels :	15
I.4.2		Méthode d'analyse retenue et données de traitement	15
I.4.2.1		Dataset utilisé : CICIDS2017	16
I.4.2.2		Prétraitement et feature engineering	16
I.4.3		Planning et chronogramme de réalisation	17
II		ANALYSE ET CONCEPTION	18
II.1		Analyse du système actuel	18
II.1.1		Problèmes identifiés sur le terrain	18
II.1.2		Fonctionnalités du système existant	18
	II.1.2.1	Architecture de sécurité - Zero Trust	19
	a)	Couche réseau - Nginx	19
	b)	Couche authentification - Keycloak + JWT	19
	c)	Gestion des rôles (RBAC)	19
	d)	Protection contre les injections de prompts	19
	e)	Contraintes du système existant	19
	II.1.2.2	Solutions proposées	20
II.1.3		Cas d'usage retenus	20
	II.1.3.1	Acteurs du système	20
II.2		Expression des besoins	21
II.2.1		Description du futur système	21
II.2.2		Fonctionnalités clés	21
II.2.3		Intégration avec le système existant	21
II.2.4		Etude de faisabilité	21
	II.2.4.1	Faisabilité technique	21
	II.2.4.2	Faisabilité économique	22
	II.2.4.3	Faisabilité organisationnelle	22
	II.2.4.4	Faisabilité temporelle	22

II.2.5	Spécification technique des besoins	22
II.2.5.1	Spécifications fonctionnelles	22
II.2.5.2	Spécifications non-fonctionnelles	23
II.3	Conception du système futur	23
II.3.1	Diagramme de cas d'utilisation	23
II.3.2	Diagramme de séquence - Agent RGPD	24
II.3.3	Diagramme de séquence - Agent cybersécurité	25
II.3.4	Diagramme de classes	26
II.3.5	Diagramme d'activité - Traitement d'une demande RGPD	29
II.3.6	Diagramme de déploiement	30
III	REALISATION	32
III.1	Choix et présentation des outils	32
III.1.1	Stack technologique	32
III.1.2	Choix et justification du modèle de classification des logs	33
III.1.2.1	Modèle retenu : Random Forest avec features engineered	33
III.1.2.2	Structure du pipeline de classification	33
a)	Etape 1 : Parsing	33
b)	Etape 2 : Feature extraction	33
c)	Etape 3 : Classification	33
d)	Etape 4 : Post-processing	34
e)	Labels de sortie et seuils de décision	34
III.2	Structure générale de l'application	34
III.2.1	Architecture du module Web - Agent RGPD	34
III.2.1.1	Présentation de l'interface Web	35
III.2.2	Architecture du module mobile - Agent cybersécurité	39
III.2.2.1	Présentation de l'interface mobile	40
III.2.3	Sécurisation de l'architecture	46
III.3	Description technique du logiciel	46
III.3.1	Architecture globale du système	46
III.3.2	Pipeline RAG - Agent RGPD	46
III.3.2.1	Phase 1 - Ingestion des documents	46
a)	Etape 1 - Chargement des documents	47
b)	Etape 2 : Découpage en fragments (Chunking)	47
c)	Etape 3 : Vectorisation (Embedding)	47
d)	Etape 4 : Indexation dans ChromaDB	48
III.3.2.2	Phase 2 - Interrogation en temps réel	48
a)	Recherche par similarité	48
b)	Construction du prompt et génération	48
III.3.2.3	API REST - Endpoints FastAPI	48
a)	Routeur Authentification - / auth	48
b)	Routeur RGPD - /rgpd	49
c)	Routeur Cybersécurité - /cyber	49
III.3.3	Modèle de classification des logs	49
III.3.3.1	Construction des features	50
III.3.3.2	Entraînement du modèle	50

III.3.3.3	Métriques d'évaluation	50
III.3.4	Implémentation Flutter	50
IV	EVALUATION DU PROJET ET PERSPECTIVES	52
IV.1	Etude des risques	52
IV.1.1	Évaluation du modèle de classification des logs	52
IV.1.1.1	Métriques retenues et justification	52
IV.1.1.2	Résultats sur le dataset de test	52
IV.1.1.3	Analyse des erreurs et limites du modèle	52
IV.1.2	Stratégies de test	53
IV.1.2.1	Tests fonctionnels	53
IV.1.2.2	Tests de sécurité	54
IV.1.2.3	Tests de pertinence de l'agent RGPD	54
IV.1.2.4	Tests de précision du modèle de classification des logs	55
IV.1.2.5	Métriques de performance	56
IV.1.3	Les risques spécifiques aux agents IA	57
IV.1.4	Gouvernance des données et contrôle humain	57
IV.2	Coût de mise en oeuvre	58
IV.3	Perspectives	58
CONSLUSION		60
BIBLIOGRAPHIE		XVI
WEBOGRAPHIE		XVII
ANNEXE		XVIII
1.8cm 6.5em		
Annexe 1—Couche réseau Nginx de l'architecture Zero Trust		XVIII
Annexe 2—Couche authentification Keycloak + JWT		XVIII
Annexe 3—Protection contre les injections de prompts		XIX
Annexe 4—Étape 1 : Chargement des documents dans la phase d'ingestion		XIX
Annexe 5—Étape 2 : Découpage en fragments ou Chunking dans la phase d'ingestion		XX
Annexe 6—Étape 3 : Vectorisation ou Embedding dans la phase d'ingestion		XX
Annexe 7—Étape 4 : Indexation dans ChromaDB durant la phase d'ingestion		XX
Annexe 8—Recherche par similarité		XXI
Annexe 9—Construction du prompt et génération		XXII
Annexe 10—Construction des features		XXIII
Annexe 11—Entraînement du modèle de classification		XXIII

Annexe 12 S tructure du projet Flutter	XXIV
Annexe 13 S tockage sécurisé du JWT (Flutter)	XXV
Annexe 14 C lient HTTP et gestion des requêtes)	XXV
Annexe 15 A nalyste de la conformité d'un traitement	XXVI
Annexe 16 R éponse contextualisée générée par le chatbot	XXVI
Annexe 17 C réation du client Dio avec injection automatique du JWT et gestion d'erreur 40X	XXVII
Annexe 18 C onfiguration de l'URL de base de l'API	XXVII
Annexe 19 O WASP Top 10 - Risques principaux	XXVIII